🛠️ Vision AI 특강 정리: 환경 설정과 CLI 연결

> 핵심 한 줄: **내 PC는 명령만 내리고, 무거운 연산은 Colab GPU가 한다.** 이 특강의 진짜 주제는 모델이 아니라 **그 연결을 위한 환경 설정**이다.

항목	내용
실습 저장소	yblee110/vision-ai-notebook
개발 환경	GitHub Codespaces (devcontainer로 자동 세팅, Python 3.12)
연결 도구	Hugging Face CLI `hf` 0.36.0 · Google Colab CLI `colab` 0.6.0
원격 연산	Colab GPU 런타임 (T4), 컴퓨팅 유닛(CU)으로 결제
실습 예제	DeiT-tiny로 병·그릇·캔·컵·접시 분류 (연결을 확인하는 예제일 뿐)

📌 목차

0. 내 소감: 막혔던 점과 깨달은 점
1. 한눈에 보기: 환경 3층 구조 + ⚡ 핵심 명령 요약
2. 왜 환경을 이렇게 나누나
3. 1층: Codespaces 개발 환경 자동 세팅
4. 실습에서 한 것 (수업 순서대로)
5. 2층: 인증 (Hugging Face, Google)
6. 3층: Colab 런타임 연결 (CLI 명령)
7. 연결 자동화: 셸 스크립트와 에이전트 스킬
8. GPU 고르기와 비용
9. 환경 트러블슈팅
10. 복습 체크리스트

0. 내 소감: 막혔던 점과 깨달은 점

😵 막혔던 점: README(마크다운)가 제대로 안 보였다

- Codespaces(VS Code)에서 `README.md`를 열면 `#`, `|`, `**` 기호가 그대로 보여서 안내를 따라가기 힘들었다.
- 환경 설정 안내가 거의 다 README에 있어서 이게 막히면 진행 전체가 막힌다.

해결법	동작
`Ctrl + Shift + V`	현재 탭을 미리보기(렌더링)로 열기
`Ctrl + K` 다음 `V`	옆 창에 미리보기 열기. 원본과 나란히 보면서 명령을 복사하기 좋다
`.md` 우클릭 → Open Preview	마우스로 열기

💡 깨달은 점: 왜 CLI로 연결하나

> **내 컴퓨터 자원(GPU·메모리)이 부족한데 모델을 돌리고 싶을 때** 쓰는 것이다.

- 내 PC와 Codespaces(CPU 2코어·8GB)에는 GPU가 없다.
- `colab` CLI는 터미널 명령 몇 줄로 **Colab GPU를 빌려와서** 코드를 실행하고 결과만 가져온다.
- 명령어라서 반복 실행, 자동화, AI 에이전트 연결까지 된다.
- 그러려면 **CLI가 돌아가는 환경**부터 제대로 만들어야 한다. 그래서 이 특강의 절반이 환경 설정이다.

🚀 앞으로 이렇게 쓸 것 같다

> 💡 **앞으로 내 컴퓨팅 환경이 부족할 때 이 방법을 사용할 것 같다.** 내 PC에 GPU가 없거나 사양이 모자라도, Codespaces에서 명령만 내리고 무거운 연산은 Colab GPU에 맡기면 된다.

1. 한눈에 보기: 환경 3층 구조



환경 3층 구조: Codespaces 자동 세팅 → 인증 → Colab 런타임

층	어디서	무엇을 맞추나	핵심 명령·파일
1층 개발 환경	Codespaces (리눅스, CPU)	Python 3.12, `.venv`, `hf` · `colab` CLI, 노트북 커널	`devcontainer.json`, `setup.sh`, `doctor.py`
2층 인증	Codespaces 터미널	누구 계정으로 HF·Colab에 접속하나	`colab --auth oauth2 sessions`
3층 원격 런타임	Colab GPU (T4)	PyTorch·Transformers 설치, GPU 확인	`colab new`, `upload`, `exec`, `stop`



데이터와 명령의 흐름: Codespaces에서 명령하고 Colab GPU가 연산

⚡ 핵심 명령 요약 (이 순서대로 따라 하면 된다)

```
# ── 1층: Codespaces 환경 (보통 자동으로 끝나 있음) ──
bash scripts/setup.sh              # 자동 설치가 실패했을 때만 다시 실행
source .venv/bin/activate
python scripts/doctor.py           # 환경 점검 (오프라인, 돈 안 듦)

# ── 모델 파일 받기 (Codespaces) ──
hf download facebook/deit-tiny-patch16-224 config.json preprocessor_config.json pytorch_model.bin \
  --revision b3428f18dcc7b543470d07f14b4a4157815d1880 --local-dir hf_colab_gpu/models/deit-tiny

# ── 2층: Google 로그인 ──
colab --auth oauth2 sessions

# ── 3층: Colab GPU 연결 (여기서부터 CU 사용) ──
colab new -s hf-vision-gpu --gpu T4
colab upload -s hf-vision-gpu hf_colab_gpu/requirements-torch.txt content/requirements-torch.txt
colab upload -s hf-vision-gpu hf_colab_gpu/requirements-gpu.txt   content/requirements-gpu.txt
colab exec -s hf-vision-gpu --timeout 1800 <<'PY'
import subprocess, sys
for f in ('/content/requirements-torch.txt', '/content/requirements-gpu.txt'):
    subprocess.run([sys.executable, '-m', 'pip', 'install', '-r', f], check=True)
PY
colab restart-kernel -s hf-vision-gpu
#   모델·데이터 업로드는 6-3 참고
colab exec -s hf-vision-gpu -f hf_colab_gpu/notebooks/01_gpu_inference.ipynb  --timeout 1800
colab exec -s hf-vision-gpu -f hf_colab_gpu/notebooks/02_gpu_finetuning.ipynb --timeout 1800
colab download -s hf-vision-gpu content/vision-ai/hf_colab_gpu/results/gpu/report.json hf_colab_gpu/
results/gpu/report.json

# ── 끝나면 꼭 ──
colab stop -s hf-vision-gpu
colab sessions                     # 목록이 비어 있으면 종료 완료
```

상황	한 줄 명령
연결 흐름만 미리 보기 (로그인·GPU 없음)	`bash hf_colab_gpu/run_pipeline_colab.sh --dry-run`
추론 시연을 한 번에 (생성 → 추론 → 회수 → 종료)	`bash hf_colab_gpu/run_pipeline_colab.sh`
지금 열린 세션이 있는지	`colab sessions`
마크다운 안내 읽기	VS Code에서 `Ctrl + Shift + V`

2. 왜 환경을 이렇게 나누나

구분	내 PC	Codespaces	Colab GPU
역할	브라우저만 있으면 됨	편집, 다운로드, CLI 명령	무거운 연산 (추론·학습)
사양	사람마다 다름 (Windows/Mac)	모두 같은 리눅스 + Python 3.12	T4 GPU 등
비용	없음	무료 사용량 (강의 안내 기준 하루 4시간 정도)	컴퓨팅 유닛(CU)

- **Codespaces를 쓰는 이유:** 학생마다 OS가 달라도 **똑같은 환경**에서 시작한다. 강사님도 "윈도우라고 하면 머리가 아프다"고 했다.
- **Colab CLI를 쓰는 이유:** Colab 노트북(웹)과 **같은 런타임**을 쓰지만, 터미널 명령이라 반복·자동화·에이전트 연결이 된다.
- **비용이 안전한 이유:** Colab Pro는 매달 CU 100개를 준다. 다 쓰면 무료 정책으로 바뀐다. RunPod(자동 충전)나 GCP(사용량 과금)는 GPU를 끄지 않으면 계속 돈이 나간다. 강의 예시로 B200을 8시간 켜두면 약 160만 원이다.

구분	Colab 노트북 (웹)	Colab CLI (터미널)
형태	웹 노트북, 구글 드라이브 연동	VS Code 같은 편집기에서 파일 작성
반복	세션 재시작·셀 재실행을 사람이 직접	스크립트를 한 번 더 실행하면 끝
잘 맞는 일	탐색, 시각화	자동화, 작업 연결, 에이전트 연동
런타임	T4, L4, A100, TPU	노트북과 **같은 런타임**

3. 1층: Codespaces 개발 환경 자동 세팅

3-1. 시작 순서

1. 수업 저장소에서 **Fork** → Owner를 내 계정으로 → **Create fork**
2. **내가 Fork한 저장소**에서 Code → Codespaces → **Create codespace on main** (머신은 2코어·8GB)
3. VS Code 화면이 떠도 설치가 계속될 수 있다. 터미널에 **준비 완료** 안내가 나올 때까지 기다린다.
4. 터미널에서 `source .venv/bin/activate` 다음 `python scripts/doctor.py`로 점검한다.
5. 00번 노트북을 열고 **커널 선택 → Jupyter 커널 → Vision AI (Codespaces CPU)**를 고른다.

> Codespace를 만들고 점검하는 동안에는 Google 로그인도, Colab GPU 할당도 일어나지 않는다. 돈이 드는 단계는 6장의 `colab new`부터다.

3-2. 자동 세팅을 만드는 파일들

파일	하는 일	핵심 설정
`.devcontainer/devcontainer.json`	Codespace의 **설계도**	사양, 자동 실행 명령, 환경 변수, VS Code 확장
`.devcontainer/Dockerfile`	기본 OS와 도구	Python 3.12 이미지 + `uv` 0.12.9
`scripts/setup.sh`	생성 직후 **자동 실행**되는 설치 스크립트	`.venv` 생성, 라이브러리 설치, 커널 등록, 점검
`requirements/codespaces.txt`	Codespaces용 라이브러리 목록 (버전 고정)	`hf` · `colab` CLI 포함 11개
`.vscode/settings.json`	기본 Python 경로	`.venv/bin/python`
`scripts/doctor.py`	오프라인 환경 점검	버전·CLI·커널·인증 저장 위치

devcontainer.json 읽기

```
{
  "build": { "dockerfile": "Dockerfile", "context": ".." },
  "hostRequirements": { "cpus": 2, "memory": "8gb", "storage": "20gb" },
  "postCreateCommand": "bash scripts/setup.sh",
  "remoteEnv": {
    "PATH": "${containerWorkspaceFolder}/.venv/bin:${containerEnv:PATH}",
    "VIRTUAL_ENV": "${containerWorkspaceFolder}/.venv",
    "MPLBACKEND": "Agg",
    "OMP_NUM_THREADS": "2"
  },
  "customizations": { "vscode": {
    "extensions": ["ms-python.python", "ms-toolsai.jupyter"],
    "settings": { "python.defaultInterpreterPath": "${workspaceFolder}/.venv/bin/python" }
  } }
}
```

설정	쉬운 설명
`build.dockerfile`	이 Dockerfile로 컨테이너를 만든다
`hostRequirements`	최소 2코어·8GB·20GB 머신을 요구한다
`postCreateCommand`	컨테이너가 처음 만들어진 직후 `setup.sh`를 **자동 실행**한다
`remoteEnv.PATH`	`.venv/bin`을 맨 앞에 둔다. 그래서 `hf`, `colab`을 경로 없이 바로 쓸 수 있다
`MPLBACKEND=Agg`	화면 없는 서버에서도 그래프를 파일로 그릴 수 있게 한다
`OMP_NUM_THREADS=2`	2코어 머신에 맞게 연산 스레드를 제한한다
`extensions`	Python·Jupyter 확장을 자동 설치한다
`defaultInterpreterPath`	노트북·터미널이 기본으로 `.venv`의 Python을 쓰게 한다

Dockerfile 읽기

```
FROM ghcr.io/astral-sh/uv:0.12.9 AS uv
FROM mcr.microsoft.com/devcontainers/python:1-3.12-bookworm
COPY --from=uv /uv /uvx /usr/local/bin/
```

- 첫 줄: `uv` 실행 파일이 든 이미지를 잠깐 가져온다.
- 둘째 줄: 실제 기반은 **Python 3.12 + Debian(bookworm)** 리눅스 이미지다.
- 셋째 줄: 첫 이미지에서 `uv`만 복사해 넣는다. `uv`는 pip보다 훨씬 빠른 설치 도구다.

`setup.sh` 핵심 줄 읽기

```
uv venv --python 3.12 --allow-existing .venv                        # ① 가상환경 만들기
uv pip install --python .venv/bin/python -r requirements/codespaces.txt   # ② 라이브러리 설치
.venv/bin/python -m ipykernel install --prefix "$LAB_ROOT/.venv" \
  --name codespaces-vision-ai --display-name 'Vision AI (Codespaces CPU)'  # ③ 노트북 커널 등록
.venv/bin/python scripts/doctor.py --configure-state-only           # ④ 인증 저장 위치 연결
.venv/bin/python scripts/doctor.py                                  # ⑤ 전체 점검
```

1. 프로젝트 안에 Python 3.12 가상환경 `.venv`를 만든다. 이미 있으면 그대로 쓴다.
2. 목록에 적힌 **정확한 버전**으로 설치한다.
3. 노트북에서 고를 커널 이름을 `Vision AI (Codespaces CPU)`로 등록한다.
4. Colab 로그인 정보가 컨테이너를 다시 만들어도 남도록 저장 위치를 연결한다 (5장).
5. 점검 결과를 보여 준다. 이 과정에서 Google 로그인이나 Colab 자원 생성은 없다.

3-3. Codespaces에 설치되는 라이브러리

패키지	버전	하는 일
`huggingface_hub[cli]`	0.36.0	`hf download` 명령
`google-colab-cli`	0.6.0	`colab` 명령
`jupyter-kernel-client`	0.9.0	Colab CLI 0.6.0이 원격 커널과 통신할 때 쓰는 부품. 버전이 맞아야 한다
`numpy`, `Pillow`, `pyarrow`	2.5.2, 12.3.0, 20.0.0	이미지 읽기, 데이터 분할
`matplotlib`	3.11.1	그래프
`ipykernel`, `nbformat`, `nbclient`	7.3.0, 5.10.4, 0.10.4	노트북 커널과 실행
`pytest`	9.1.1	수업 코드 검사

> **PyTorch는 여기 없다.** GPU용 PyTorch는 Codespaces가 아니라 Colab에 설치한다 (6장). 그래서 Codespaces에서 01·02 노트북을 Run All 하면 `import torch`부터 에러가 난다.

3-4. 환경 점검: `doctor.py`

```
source .venv/bin/activate
python scripts/doctor.py
python -c "import sys; print(sys.executable)"
```

점검 항목	확인 내용
`python`	3.12인지, `.venv` 안의 Python인지
패키지 11개	목록의 버전과 정확히 같은지
`colab executable`	`colab --help`가 실행되는지
`Hugging Face executable`	`hf --help`가 실행되는지
`Colab execution API`	`jupyter-kernel-client`가 CLI와 호환되는지 (연결은 안 함)
`notebook kernel`	등록된 커널이 이 `.venv`를 가리키는지
`credential persistence`	로그인 정보 저장 위치가 연결됐는지

`doctor.py`는 **오프라인 점검**만 한다. 로그인, GPU 할당, 모델 다운로드는 하지 않는다.

3-5. 환경이 이상할 때

- `.venv`가 없거나 자동 설치가 실패했다 → 오류를 읽고 `bash scripts/setup.sh`를 다시 실행한다.
- `uv`가 없다거나 설정 파일을 고쳤다 → 작업을 저장한 뒤 명령 팔레트에서 **Codespaces: Rebuild Container**.
- `ModuleNotFoundError` → 셀에 설치 명령을 넣기 전에 **커널이 Vision AI (Codespaces CPU)인지** 먼저 확인한다.
- 커널 목록에 안 보인다 → 커널 선택 → **다른 커널 선택**에서 찾는다.

4. 실습에서 한 것 (수업 순서대로)

수업 시간에 실제로 따라 한 순서다.

순서	한 일	어디서
1	수업 저장소를 **Fork**해서 내 계정으로 복사	GitHub
2	내 Fork에서 **Create codespace on main**, 자동 설치가 끝날 때까지 대기	Codespaces
3	README를 보며 진행 (마크다운 미리보기가 안 돼서 헤맴)	Codespaces
4	**00번 노트북** 실행 (아래 설명)	Codespaces CPU
5	**Google 로그인**: `colab --auth oauth2 sessions` → 링크 `Ctrl + 클릭` → 계정 선택 → 코드를 복사해 터미널에 붙여넣기	Codespaces 터미널
6	**세션 생성**: `colab new -s 이름 --gpu T4`	Colab
7	**GPU 라이브러리 설치** (PyTorch 등). 오래 걸리고, 설치 후 커널 재시작이 필요	Colab
8	**01번 GPU 추론**: `pipeline()`으로 컵 이미지 추론	Colab GPU
9	**02번 파인튜닝**: 5개 클래스 분류기 학습 → 마지막 블록까지 학습	Colab GPU
10	마지막에 **에이전트 스킬**(`vision-pipeline-inference`) 소개	강의

00번 노트북에서 한 것

1. 커널을 **Vision AI (Codespaces CPU)**로 선택
2. 프로젝트 위치와 Python 경로가 `.venv` 인지 확인
3. 라이브러리 확인 (NumPy, Pillow, Matplotlib)
4. `hf download`로 모델 파일 3개 받기
5. 받은 파일의 SHA-256 지문이 원본과 같은지 확인
6. CIFAR-100 원본을 받아 5개 클래스만 골라 학습 500 · 검증 100 · 테스트 200장으로 나누기
7. 클래스별 이미지 확인 (32×32라서 많이 흐릿하다)

```
hf download facebook/deit-tiny-patch16-224 config.json preprocessor_config.json pytorch_model.bin \
  --revision b3428f18dcc7b543470d07f14b4a4157815d1880 \
  --local-dir hf_colab_gpu/models/deit-tiny
```

- `--revision`은 모델의 **지문(커밋 SHA)** 이다. 고정하면 모두가 같은 파일로 실험한다.

- 받는 파일 3개: `config.json`(설정), `preprocessor_config.json`(전처리), `pytorch_model.bin`(가중치, 약 23MB).

01번에서 본 것

```
image_classifier = pipeline(
    "image-classification",      # 무슨 작업? → 이미지 분류
    model=model,                 # 업로드한 DeiT
    image_processor=processor,   # 업로드한 전처리 설정
    framework="pt",              # PyTorch
    device=device,               # Colab GPU
)
predictions = image_classifier(image, top_k=5)
```

- 컵 사진을 넣었더니 **face powder** 같은 엉뚱한 라벨이 나왔다.
- 원본 모델은 ImageNet 1,000개 라벨로 학습돼서 "컵"을 모른다. 그래서 02번에서 5개 클래스로 다시 학습한다.

강사님 시연에서 본 것

- 세션 이름을 안 주면 `92c9d...` 같은 이름이 붙는다. 그래서 `-s`로 이름을 정한다.
- GPU를 안 정하면 TPU가 붙는다. 그래서 `--gpu T4`를 꼭 쓴다.
- 다 쓴 세션은 `colab stop -s 이름`으로 지우고 `colab sessions`로 확인한다.

실습하면서 느낀 점

- Codespaces에서 01번을 그냥 실행하면 `torch`가 없다는 에러가 난다. 01·02는 **Colab에서** 돌려야 한다는 걸 이때 알았다.
- 사람마다 진행 속도가 달라서 끝까지 못 간 사람도 있었다. 강사님은 수업이 끝난 뒤 **흐름을 글로 다시 정리**해 보라고 했다.

5. 2층: 인증 (누구 계정으로 연결하나)

Hugging Face

- 이번 모델 `facebook/deit-tiny-patch16-224`는 공개 모델이라 **로그인이 필요 없다.**
- Gemma처럼 라이선스 동의가 필요한(gated) 모델은 `hf auth login`이 필요할 수 있다.
- 토큰은 노트북·커밋·업로드 파일에 절대 넣지 않는다.

Google (Colab CLI)

```
colab --auth oauth2 sessions
```

1. 위 명령을 **터미널에서 직접** 실행한다. `colab login` 명령은 0.6.0에 없다.
2. 터미널에 나온 링크를 `Ctrl + 클릭`해서 브라우저로 연다.
3. 본인 Google 계정을 고르고 권한을 허용한다.

4. 받은 코드를 복사해 터미널에 붙여 넣는다.
5. `No active sessions` 같은 목록이 나오면 로그인 성공이다.

인증 방식	누가 쓰나	사용법
`oauth2`	학생 (기본값)	`colab --auth oauth2 ...`
`adc`	ADC(Google 기본 인증)를 이미 준비한 강사	모든 명령에 `--auth adc` 를 **일관되게** 붙인다

로그인 정보는 어디에 저장되나

- `setup.sh` 가 `~/.config/colab-cli` 를 프로젝트의 `.local-state/colab-cli` 로 연결한다 (권한 700).
- 그래서 **컨테이너를 다시 빌드해도 로그인이 유지**된다.
- `.local-state` 는 `.gitignore` 와 `.dockerignore` 에 들어 있어서 **git에 올라가지 않는다.**

6. 3층: Colab 런타임 연결 (CLI 명령)

6-1. 핵심 명령어

명령	의미
`colab --auth oauth2 sessions`	로그인과 열린 세션 목록 확인
`colab new -s 이름 --gpu T4`	새 GPU 세션 생성. **여기서부터 CU 사용**
`colab status -s 이름`	세션 상태 확인
`colab upload -s 이름 로컬경로 원격경로`	파일 올리기
`colab exec -s 이름 --timeout 초`	원격에서 Python 실행 (`-f 파일` 로 노트북·스크립트 실행)
`colab restart-kernel -s 이름`	원격 커널 재시작
`colab download -s 이름 원격경로 로컬경로`	결과 파일 받기
`colab stop -s 이름`	**세션 종료**
`colab sessions`	종료됐는지 확인

6-2. 세션을 열고 원격 환경 만들기

```
# 1) 세션 생성과 확인
colab new -s hf-vision-gpu --gpu T4
colab status -s hf-vision-gpu

# 2) 설치 목록 올리기
colab upload -s hf-vision-gpu hf_colab_gpu/requirements-torch.txt content/requirements-torch.txt
colab upload -s hf-vision-gpu hf_colab_gpu/requirements-gpu.txt   content/requirements-gpu.txt

# 3) 원격에서 pip 설치 (30분까지 기다림)
colab exec -s hf-vision-gpu --timeout 1800 <<'PY'
import subprocess, sys
subprocess.run([sys.executable,'-m','pip','install','-r','/content/requirements-torch.txt'], check=T
rue)
subprocess.run([sys.executable,'-m','pip','install','-r','/content/requirements-gpu.txt'], check=Tru
e)
print('HF_GPU_LIBRARIES_READY')
PY

# 4) 새 버전 반영
colab restart-kernel -s hf-vision-gpu

# 5) GPU가 정말 붙었는지 확인
colab exec -s hf-vision-gpu --timeout 120 <<'PY'
import torch
assert torch.cuda.is_available(), 'GPU를 찾지 못했습니다.'
print('GPU:', torch.cuda.get_device_name(0))
PY
```

단계	왜 이렇게 하나
`-s hf-vision-gpu`	이름을 안 주면 `92c9d...` 같은 임의 이름이 붙어 관리가 어렵다
`--gpu T4`	안 주면 TPU가 붙는다 (강의 시연)
`colab install` 대신 `exec`와 `pip`	0.6.0의 `install`은 대기시간이 약 60초라 큰 PyTorch 설치가 중간에 끊긴다
`--timeout 1800`	단위는 **초**. 1800초 = 30분. 출력 없이 오래 걸리는 작업이 끊기지 않게 넉넉히 준다
`restart-kernel`	설치 전에 메모리에 올라간 옛 버전과 섞이지 않게 한다
`torch.cuda.is_available()`	GPU가 없으면 CPU로 몰래 돌리지 말고 **멈춘다**
`<<'PY' ... PY`	셸의 here-document. 사이에 적은 Python 코드를 그대로 원격에 보낸다

Colab에 설치하는 버전

파일	내용
`requirements-torch.txt`	CUDA 12.6용 공식 배포처에서 `torch==2.8.0`, `torchvision==0.23.0`
`requirements-gpu.txt`	`transformers==4.57.6`, `huggingface_hub==0.36.0`, `safetensors==0.8.0`, `numpy`, `Pillow`, `matplotlib`

6-3. 원격 경로 규칙

```
# 업로드는 상위 폴더를 자동으로 만들지 않는다 → 먼저 exec로 폴더 만들기
colab exec -s hf-vision-gpu --timeout 120 <<'PY'
from pathlib import Path
Path('/content/vision-ai/data/prepared').mkdir(parents=True, exist_ok=True)
PY
colab upload -s hf-vision-gpu data/prepared/train.npz content/vision-ai/data/prepared/train.npz
```

- CLI의 파일 경로 `content/vision-ai/...` 는 Colab 안 Python에서 `/content/vision-ai/...` 이다. 앞의 `/` 유무만 다르다.
- 모델·데이터는 노트북과 **따로 올려야** 한다. 노트북만 실행한다고 파일이 따라가지 않는다.
- `exec -f`는 **로컬 파일의 내용**을 보내서 실행한다. 그래서 원격 코드에서 `__file__`에 기대면 안 된다.

6-4. 실행, 회수, 종료

```
colab exec -s hf-vision-gpu -f hf_colab_gpu/notebooks/01_gpu_inference.ipynb  --timeout 1800
colab exec -s hf-vision-gpu -f hf_colab_gpu/notebooks/02_gpu_finetuning.ipynb --timeout 1800
colab download -s hf-vision-gpu content/vision-ai/hf_colab_gpu/results/gpu/report.json hf_colab_gpu/
results/gpu/report.json
colab stop -s hf-vision-gpu
colab sessions
```

> ⚠️ **꼭 기억할 것**
>
> 1. 세션은 **자동으로 꺼지지 않는다.** `stop` 후 `sessions`로 비었는지 확인한다.
> 2. `--timeout`은 셀 대기시간이지 **자동 종료 시간이 아니다.**
> 3. CLI는 셀 오류가 나도 **뒤 셀을 계속 실행**한다. 명령이 끝났다고 성공이 아니다. `*_output.ipynb`에서 오류를 확인한다.
> 4. 오류가 났다고 새 세션을 계속 만들지 않는다. 기존 세션 상태부터 확인한다.
> 5. 끝나면 **Colab 세션 종료 + Codespace 중지** 둘 다 한다. 사용량이 따로 계산된다.

7. 연결 자동화: 셸 스크립트와 에이전트 스킬

7-1. 명령 9개를 스크립트 하나로

`hf_colab_gpu/run_pipeline_colab.sh`는 6장의 명령들을 순서대로 묶은 셸 파일이다. `--dry-run`은 로그인·GPU 없이 **계획만** 보여 준다.

```
bash hf_colab_gpu/run_pipeline_colab.sh --dry-run      # 계획만 확인
colab --auth oauth2 sessions                            # 첫 로그인은 직접
bash hf_colab_gpu/run_pipeline_colab.sh                 # 실제 실행: 새 T4 → 추론 → 회수 → 종료
bash hf_colab_gpu/run_pipeline_colab.sh --image custom_images/my-cup.png
```

7-2. 스크립트에서 배울 환경 설계

```
set -Eeuo pipefail          # 오류가 나면 즉시 멈춘다
umask 077                   # 새로 만드는 파일을 나만 읽게 한다
CLI=("$COLAB_BIN" --auth "$AUTH")   # 인증 방식을 모든 명령에 똑같이 붙인다

step() {                    # 원격 로그는 화면 대신 비공개 파일에 저장
    local label=$1; shift
    "$@" >"$OUTPUT/logs/$label.log" 2>&1 || { echo "단계 실패: $label"; return 1; }
}
trap cleanup EXIT           # 성공·실패·Ctrl+C 어떤 경우든 마지막에 cleanup 실행
```

설계	이유
`set -Eeuo pipefail`	중간 단계가 실패했는데 다음 단계로 넘어가 CU를 낭비하지 않게
`sessions` 스냅숏 전·후 비교	이름이 겹치는 세션이 있으면 시작 전에 멈추고, **내가 만든 세션만** 찾아낸다
`trap cleanup EXIT`	어떤 이유로 끝나든 **이번에 만든 세션만** `stop`하고 목록에서 사라졌는지 확인
로그를 `logs/`에 저장	수업 화면(프로젝터)에 인증 정보가 노출되지 않게
버전 검사	원격에 설치된 버전이 수업 버전과 다르면 실패 처리

> "끄는 걸 깜빡해서 요금이 나가는" 위험을 **코드로 막은 것**이다. 6장의 주의점이 그대로 자동화돼 있다.

7-3. 에이전트 스킬로 연결

```
스킬(SKILL.md)  →  셸 파일(.sh)  →  Colab CLI  →  Python pipeline()  →  결과 JSON
```

- 스킬은 AI 코딩 도구가 읽는 **작업 안내서**다. 위치는 `.agents/skills/vision-pipeline-inference/SKILL.md`.
- 에이전트에게 "이 이미지를 Colab에서 추론해 줘"라고 하면 에이전트가 이 셸 파일을 호출한다.
- 터미널 명령과 `--help` 문서만 있으면 UI 없이도 에이전트가 도구를 쓸 수 있다. **CLI가 다시 주목받는 이유**다.
- Colab CLI가 올해 초 나오고 HF CLI도 최근 나온 이유가 **에이전트 통합**이다.

8. GPU 고르기와 비용

단계	추천	이유
처음 실험	**T4**	가볍고 CU를 적게 쓴다. 이번 실습은 T4로 충분
모델 키우기	**L4**	T4보다 메모리가 커서 조금 더 좋은 모델
본격 실험	**A100**	큰 모델, 빠른 학습. CU를 많이 쓴다
특수	**TPU** (v5e-1, v6e-1)	메모리가 매우 크지만 JAX 같은 전용 라이브러리가 필요

- H100·G4는 Colab Pro+가 필요하다.

- 전략: **작게 시작(T4) → 모델 키우기(L4) → 큰 GPU(A100)**.
- 추천 순서: **Colab CLI로 안전하게 → 익숙해지면 RunPod → 필요하면 GCP**.

9. 환경 트러블슈팅

증상	원인	해결
README가 기호투성이	마크다운 원본 보기	`Ctrl+Shift+V`
Windows에서 `colab`이 실행되지 않음	Colab CLI는 Linux·macOS만 지원	Codespaces 또는 WSL에서 실행
`google-colab-cli` 설치 실패	Python 3.12 미만	Python 3.12 환경 (`uv venv --python 3.12`)
`.venv`가 없음	자동 설치 실패	`bash scripts/setup.sh`
`uv`를 찾을 수 없음	컨테이너가 옛 설정	Codespaces: Rebuild Container
`ModuleNotFoundError`	다른 커널 선택	커널을 Vision AI (Codespaces CPU)로
01·02 Run All에서 `torch` 오류	Codespaces엔 PyTorch 없음	`colab exec -f`로 Colab에서 실행
`colab login`이 없음	0.6.0에 없는 명령	`colab --auth oauth2 sessions`
로그인 링크가 안 열림	터미널 링크	`Ctrl + 클릭` → 계정 선택 → 코드 붙여넣기
PyTorch 설치가 끊김	`colab install` 대기시간 짧음	requirements 업로드 후 `exec --timeout 1800`
설치했는데 import 이상	옛 버전이 메모리에 남음	`colab restart-kernel`
`upload` 실패	상위 폴더 자동 생성 안 됨	먼저 `exec`로 `mkdir`
같은 이름 세션이 있음	이전 세션이 안 꺼짐	`colab sessions` 확인 후 `stop` 또는 새 이름
명령은 끝났는데 결과가 이상	셀 오류 후에도 계속 실행됨	`*_output.ipynb`에서 오류 확인

10. 복습 체크리스트

> 🗣️ 강사님: "코드 한 줄 한 줄보다 **어떤 흐름으로 무슨 일을 하는지**가 머릿속에 들어가야 한다. 흐름을 말이나 글로 정리해 봐야 한다."

- ☐ 환경 3층(Codespaces, 인증, Colab 런타임)을 그림 없이 설명할 수 있다
- ☐ `devcontainer.json` → `Dockerfile` → `setup.sh` → `.venv` 순서를 안다
- ☐ Colab CLI가 Python 3.12와 리눅스·맥이 필요하다는 것을 안다
- ☐ `doctor.py`로 환경을 점검하고 결과를 읽을 수 있다
- ☐ `colab --auth oauth2 sessions`로 로그인할 수 있다
- ☐ PyTorch가 Codespaces가 아니라 Colab에 설치되는 이유를 안다
- ☐ `new → upload → exec → restart-kernel → exec -f → download → stop → sessions` 순서를 안다

- ☐ `content/...`와 `/content/...`의 차이를 안다
- ☐ `--timeout`이 초 단위이고 자동 종료가 아님을 안다
- ☐ 실습 후 **Colab 세션 종료 + Codespace 중지**를 했다 ⭐