SlowPaper: CLIP 다시 읽기

Learning Transferable Visual Models From Natural Language Supervision (Radford et al., OpenAI, 2021)
arXiv 2103.00020

수업에서 함께 본 CLIP 논문을 다시 읽고 다섯 가지 질문에 답한 회고입니다.

> 모두의연구소 AX Bootcamp · 컴퓨터 비전 · SlowPaper

1. 왜 이 논문을 선택했는가

솔직히 말하면 과제 주제로 정해진 논문이라 읽게 됐다. 그런데 다시 읽어 보니 노드 8 실습에서 이미 쓰고 있던 부품이었다.

Stable Diffusion에 "a crack on the PCB" 같은 문장을 넣으면, 그 문장을 숫자로 바꾸는 텍스트 인코더가 CLIP이었다. 정해져서 읽기 시작했지만, 이름만 알고 쓰던 부품이 무슨 원리로 돌아가는지 알게 되면서 읽을 이유가 생겼다.

교수님이 왜 이 논문을 고르셨는지도 생각해 봤다. 처음엔 그냥 유명한 논문이라서인 줄 알았는데, 같이 학습해 보니 이상 탐지 시간의 임베딩·대조 학습, 생성 모델 시간의 SD 텍스트 인코더, 라벨링 비용 이야기가 전부 CLIP에서 만난다. 지금까지 배운 걸 한 번에 묶어 보라는 뜻이었던 것 같다.

2. 어떤 연구 분야인가

사진과 글을 한 모델에서 같이 다루는 **멀티모달(Vision-Language)** 분야다. 사람이 붙인 클래스 번호 대신 인터넷 사진에 원래 달려 있던 글을 정답 삼아 배우고(**자연어 지도 학습, Natural Language Supervision**), 짝이 맞는 사진-글은 가깝게, 안 맞는 것은 멀게 두는 **대조 학습(Contrastive Learning)** 을 쓴다. 목표는 한 번 학습한 모델을 추가 학습 없이 새 분류 문제에 바로 쓰는 **제로샷 전이(Zero-shot transfer)** 다.

수업에서 이게 지도 학습인지 자기 지도 학습인지 헷갈렸는데, 사람이 라벨을 따로 달지 않고 데이터에 원래 붙어 있던 글을 정답으로 쓴다는 점에서 데이터 자체에서 정답을 얻는 쪽에 가깝다고 정리했다.

3. 어떤 문제가 있었는가

비싼 라벨링 비용과 고정된 클래스 목록.

기존 이미지 분류 모델은 `[cat, dog, car, …]`처럼 학습할 때 정한 목록 안에서만 답한다. 마지막 층의 출력 개수가 클래스 수로 고정되어 있어서, "고양이"를 "단모 고양이 / 회색 고양이"로 더 잘게 나누고 싶으면 그 사진을 모아 라벨을 다시 달고 다시 학습해야 한다.

공장으로 바꿔 보면, 불량을 "정상 / 긁힘 / 부품 누락"으로 학습한 분류기는 "납땜 과다"라는 새 불량이 나와도 셋 중 하나로 답한다. 새 불량이 생길 때마다 사진 수집, 라벨링, 재학습을 반복해야 한다.

방식	예	한계
사람이 직접 라벨링	ImageNet (클래스 1000개)	라벨링 비용이 커서 데이터를 키우기 어렵다
약한 라벨 대량 사용	인스타그램 해시태그, JFT-300M	데이터는 크지만 클래스 목록은 여전히 고정
글에서 직접 배우기	VirTex, ICMLM, ConVIRT	데이터가 작아 제로샷 성능이 낮다 (ImageNet 11.5%, Li et al. 2017)

4. 그 문제를 어떻게 해결하면 좋을까

① **라벨 대신 글을 정답으로**: 인터넷에서 사진-글 쌍 4억 개(WIT)를 모았다. 글은 사진에 원래 붙어 있던 것이라 라벨링 비용이 없다.

② **이미지와 글을 같은 공간에** (Figure 1):

- 이미지 인코더(ResNet 또는 Vision Transformer)는 사진을, 텍스트 인코더(Transformer, 글은 Byte Pair Encoding으로 쪼갬)는 글을 각각 임베딩 벡터(`e_img`, `e_txt`)로 바꾼다.
- 처음에는 두 벡터가 서로 다른 특징 공간에서 출발한다. 같은 대상(강아지 사진과 "강아지"라는 글)을 가리키면 두 벡터가 가까워지도록 학습해서, 결국 하나의 공간에 모이게 한다.

③ **대조 학습** (Figure 3 의사코드): 한 배치에 사진 N장, 글 N개를 넣고 모든 조합의 코사인 유사도(정규화한 벡터의 내적)로 N×N 표를 만든다.

```
          글1    글2    글3
사진1    [짝]    X      X
사진2     X    [짝]     X
사진3     X     X     [짝]
```

대각선(positive sample)은 유사도가 높아지고 나머지(negative sample)는 낮아지도록, 사진→글, 글→사진 두 방향으로 cross entropy를 구해 평균 낸다. 배치 크기가 32,768이라 한 번에 비교하는 negative가 아주 많고, 그래서 비슷한 것끼리도 구분하도록 배운다.

처음에는 사진을 보고 캡션을 단어 그대로 만들어 내게 했는데 너무 느렸다. "이 글 묶음 중 짝이 어느 것인가"만 고르게 바꾸면서 학습 효율이 크게 좋아졌다(Figure 2).

④ **제로샷 분류**: 클래스 이름으로 "a photo of a {클래스}." 문장을 만들어 텍스트 벡터로 바꾸고, 사진 벡터와 가장 유사한 문장의 클래스를 답으로 고른다. 클래스를 바꾸려면 문장만 바꾸면 되니, 3번의 고정된 목록 문제가 사라진다.

5. 시도한 결과는 어떠한가

결과	숫자
제로샷 ImageNet 정확도	11.5% (이전 연구) → **76.2%** (ImageNet 128만 장으로 학습한 ResNet-50과 비슷)
프롬프트 "A photo of a {label}."	클래스 이름만 쓸 때보다 +1.3%
프롬프트 80개 앙상블	추가 +3.5% (합쳐서 약 +5%)
제로샷 vs 라벨 몇 장 (Figure 6)	같은 특징으로 클래스당 4장을 학습한 선형 분류기와 평균적으로 비슷
분포 변화 (스케치, 그림 등, Figure 13)	ImageNet 대비 성능 하락 폭을 최대 75%까지 줄임

가장 기억에 남는 것은 **강건성(robustness)** 이다. 같은 바나나를 사진, 스케치, 그림으로 바꿔도 CLIP은 성능이 크게 떨어지지 않았다. 특정 데이터셋 하나에 맞춰 학습하지 않았기 때문에, 그 데이터셋에만 있는 우연한 패턴을 외우지 않은 것으로 이해했다.

한계 (논문 6장)

- 꽃·자동차 모델 같은 세밀한 구분, 물체 개수 세기 같은 추상적인 문제에 약하다.
- 학습 데이터에 거의 없던 종류에는 약하다. 손글씨 숫자 MNIST는 88%로, 픽셀에 바로 로지스틱 회귀를 쓴 것보다 낮다.
- 프롬프트를 어떻게 쓰느냐에 따라 결과가 달라지고, 각 분야 최고 성능에 닿으려면 연산이 약 1000배 더 필요하다고 추정한다.

6. 내 생각: 공장 결함 검사에 쓴다면

제로샷 그대로는 어려울 것 같다. 인터넷에 PCB 결함 사진과 그 결함을 설명한 글이 같이 올라온 경우는 드물어서, CLIP에게 PCB 결함은 MNIST처럼 처음 보는 데이터에 가깝다. 노드 8에서 Stable Diffusion이 PCB 균열을 잘 못 그린 것도, 텍스트 인코더인 CLIP이 "PCB 균열"을 잘 모르기 때문일 수 있다고 생각한다.

그래도 CLIP의 이미지 특징은 그대로 두고 결함 사진 몇 장으로 작은 분류기만 학습하는 방법(few-shot linear probe)은 해 볼 만하다. 논문에서 제로샷이 클래스당 4장 학습과 비슷했으니, 불량 사진이 적은 공장에서 시작점으로 쓸 수 있을 것 같다. 결함 문장도 "crack"처럼 짧게 쓰기보다 "a photo of a printed circuit board with a missing component"처럼 물체와 결함을 구체적으로 적어야 할 것 같다.

회고

Keep

- 노드 8에서 썼던 Stable Diffusion 텍스트 인코더가 CLIP이었다는 걸 알고 나니, 실습이랑 연결해서 읽을 수 있었다.
- 교수님이 왜 이 논문을 고르셨을지 생각해 보다가, 그동안 배운 임베딩, 대조 학습, 생성 모델이 어떻게 이어지는지 정리가 됐다.
- 개념마다 공장 상황(새로운 불량, PCB 결함 문장)에 넣어 보면서 이해했다.
- AI랑 같이 논문을 읽었다. 모르는 건 설명을 들으면서 이해했고, 정리한 숫자는 원문이랑 하나씩 맞춰 봤다.

Problem

- 사진이랑 글이 처음부터 같은 공간에 있는 줄 알았다. 다시 읽어 보니 두 인코더는 서로 다른 공간에서 시작해서 학습하면서 맞춰지는 거였다.
- 지도 학습인지 자기 지도 학습인지 준지도 학습인지 헷갈렸다.
- 영어 논문에 48쪽이나 돼서 원문을 처음부터 끝까지 읽기는 힘들었다.

Try

- ☐ 알박기 감지 프로젝트에 CLIP을 써 봐야겠다. "사람이 앉아 있는 자리", "가방만 놓인 빈자리" 같은 문장만으로 라벨 없이 자리 상태를 나눌 수 있는지 확인해 보고 싶다.
- ☐ 프로젝트에서 데이터가 모자라서 생성형 AI로 여러 상황을 만들어야 한다면, 만든 사진 중에 이상한 걸 걸러 내는 단계가 필요할 것 같다. 그런 필터가 필요해지면 CLIP으로 문장이랑 맞는 사진만 골라 써 봐야겠다.
- ☐ 다른 논문도 찾아 읽어 봐야겠다. 이때 구조와 원리를 하나하나 파고들기보다는, "이게 이래서 이렇게 쓸 수 있겠구나"를 파악하는 연습을 해 봐야겠다.