제조업 실시간 이상 탐지 시스템 구축 실습



목차

1. 강의 목표
2. 제조업 이상탐지의 현실과 도전과제
3. 이상탐지 알고리즘 개요
4. 딥러닝 기반 이상탐지 구현 실습
5. 실시간 웹 시스템 구축 실습
6. 성능 평가 및 실제 적용 가이드



강의 목표

제조업 실시간 이상 탐지 시스템 구축 실습

핵심 목표

- 제조업에서 컴퓨터 비전 기반 이상 탐지의 필요성과 도전과제 파악
- 다양한 이상 탐지 알고리즘의 특징과 적용 시나리오 이해
- 실시간 처리를 위한 시스템 아키텍처 설계 원리 습득
- 이상 탐지 모델을 직접 구현하고 훈련
- OpenCV와 Gradio를 활용한 실시간 비전 시스템 구축

제조업 이상탐지의 현실과 도전과제

제조업 이상탐지의 현실과 도전과제

- 제조업 품질검사의 현재 상황
  - 전통적 검사 방식의 한계
    - 인력 의존성: 숙련 검사자의 주관적 판단
    - 속도 제한: 생산 라인 속도 대비 검사 속도 부족
    - 피로도 영향: 장시간 작업 시 정확도 저하
    - 비용 증가: 인건비 상승과 재교육 비용
  - 현실적 데이터 문제
    - 불균형 데이터: 정상품 99% vs 불량품 1%
    - 라벨링 어려움: 불량 유형의 다양성과 복잡성
    - 실시간 요구: 밀리초 단위 판정 필요
    - 환경 변화: 조명, 온도, 진동 등의 영향

제조업 이상탐지의 현실과 도전과제

- 이상탐지와 일반 분류의 차이점
  - 학습 데이터, 목표, 평가 기준, 적용 상황별 차이 존재

구분	일반 분류	이상탐지
학습 데이터	정상 + 비정상 균형	주로 정상 데이터만
목표	클래스 분류	정상 범위 학습
평가 기준	전체 정확도	이상 탐지율 vs 오탐율
적용 상황	알려진 패턴 분류	미지의 이상 패턴 탐지

- 이상탐지 접근법의 특징
  - 정상 데이터 중심
    - 학습정상 제품의 특성만 학습
    - 새로운 불량 유형에도 대응 가능
    - 실제 제조업 환경에 적합

제조업 이상탐지의 현실과 도전과제

- 제조업 현장의 도전과제
  - **인간 검사의 한계**: 피로도, 주관성, 속도 제한
  - **복잡한 불량 패턴**: 미세한 스크래치, 색상 변화, 형태 이상
  - **실시간 처리 필요**: 생산 라인 속도에 맞춘 즉시 판정
  - **다양한 제품군**: 제품별 다른 품질 기준과 검사 항목

제조업 이상탐지의 현실과 도전과제

- 컴퓨터 비전 기반 이상탐지 시스템의 가치
  - **일관된 품질 검사**: 24시간 동일한 기준으로 검사
  - **미세한 결함 탐지**: 인간의 눈으로 놓치기 쉬운 결함 발견
  - **실시간 피드백**: 즉시 불량품 분리 및 공정 조정
  - **데이터 축적**: 불량 패턴 분석을 통한 공정 개선

- 적용 분야
  - **표면 결함 검사**: 스크래치, 찍힘, 변색 등
  - **조립 상태 검증**: 부품 누락, 잘못된 조립
  - **안전 모니터링**: 작업자 안전장비 착용, 위험 구역 진입
  - **장비 상태 감시**: 장비 외관 변화, 누유, 부식 등

제조업 이상탐지의 현실과 도전과제

- 제조업 이미지 데이터의 특성
  - **조명 조건 변화:** 시간대, 날씨에 따른 조명 변화
  - **높은 해상도 요구:** 미세한 결함 탐지를 위한 고해상도
  - **실시간 처리:** 생산 속도에 맞춘 밀리초 단위 처리
  - **환경적 요인:** 진동, 먼지, 온습도 변화

- 이상 탐지 접근법의 특징
  - **정상 데이터 중심:** 정상 제품 이미지만으로 학습
  - **다양한 불량 유형:** 예측하기 어려운 새로운 불량 패턴
  - **지역적 vs 전역적:** 특정 부위 vs 전체적인 이상
  - **임계값 설정:** 민감도와 특이도 간의 균형

제조업 이상탐지의 현실과 도전과제

접근 방법	핵심 기술	장점	단점	적용 사례
전통적 이미지 처리	필터링, 모폴로지, 에지 검출	빠른 처리, 해석 용이	복잡한 패턴 한계	단순 결함 검사
기계학습 기반	SVM, Random Forest + 특성 추출	중간 복잡도 처리	특성 설계 필요	분류 가능한 결함
딥러닝 분류	CNN, ResNet, EfficientNet	높은 정확도	라벨 데이터 필요	알려진 불량 유형
비지도 학습	Autoencoder, VAE, GAN	새로운 불량 탐지	해석성 부족	미지의 불량 패턴
시각적 기하학	Template Matching, OCR	정확한 위치/텍스트	변형에 취약	조립 검증, 문자 인식

이상탐지 알고리즘 개요

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 이상 탐지란?
  - 통계적 방법론이나 규칙 기반 시스템, 이미지 처리 기법을 사용
  - 데이터에서 일반적인 패턴과 다른 "이상"을 감지
  - 정상 상태에 대한 명확한 정의를 기반으로, 이를 벗어나는 경우를 탐지.
- 주요 특징
  - 해석 용이성: 알고리즘의 작동 방식이 비교적 명확하고 직관적임.
  - 계산 비용: 일반적으로 딥러닝 모델보다 계산량이 적어 빠른 처리가 가능.
  - 사전 지식 활용: 도메인 전문가의 지식을 규칙이나 파라미터로 반영 용이.
- 접근 방식 분류
  - 통계 기반 접근법
  - 이미지 처리 기반 접근법 (제조업 비전 검사에서 주로 활용)
  - 기타: 거리 기반, 밀도 기반 등 고전적 데이터 마이닝 기법

이상탐지 알고리즘 개요 – 전통적 이상탐지

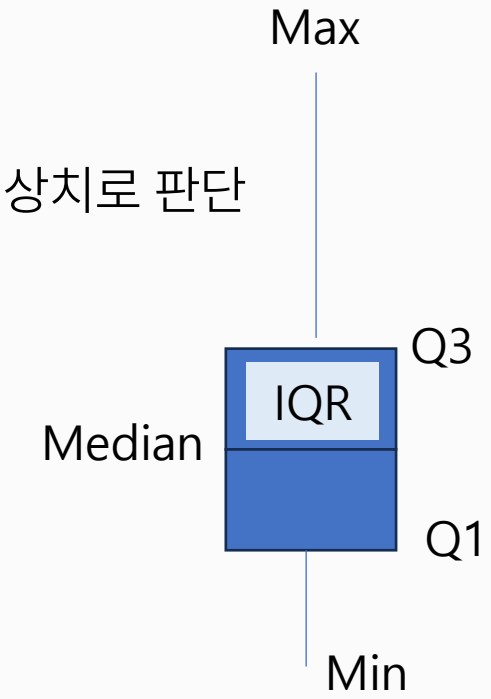
- 통계 기반 이상 탐지 - 분포 및 임계값 기반
  - 가우시안 모델 (Gaussian Models) / 정규 분포 기반
    - 정상 데이터가 정규 분포(또는 다른 특정 통계 분포)를 따른다고 가정.
    - 방법:
      - 데이터의 평균(μ)과 표준편차(σ)를 계산.
      - 새로운 데이터 포인트가 이 분포에서 나타날 확률을 계산하거나, 평균으로부터 특정 표준편차 이상 벗어나면 이상으로 판단 (예: μ±3σ 범위 밖).
    - 활용 예시
      - 제품의 특정 측정값(길이, 무게, 두께)이 평소와 현저히 다른 경우. 센서에서 수집되는 연속적인 데이터의 이상 감지.

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 통계 기반 이상 탐지 - 분포 및 임계값 기반
  - 임계값 기반 방법 (Thresholding)
    - 개념: 특정 지표에 대해 사전에 정의된 상한 또는 하한 임계값을 설정.
    - 방법: 관측값이 설정된 임계값을 벗어나면 이상으로 간주.
    - 활용 예시:
      - 이미지 특정 영역의 평균 밝기가 기준보다 현저히 어둡거나 밝은 경우 (예: 조명 불량, 이물질).
      - 제품 표면 온도가 허용 범위를 초과하는 경우.

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 통계 기반 이상 탐지 - 단변량 이상치 탐지
  - Z-점수 (Z-score) / 표준 점수 기준
    - 데이터 포인트가 평균으로부터 몇 표준편차만큼 떨어져 있는지를 나타내는 값.
    - 계산: $Z=(X-\mu)/\sigma$ (X: 개별 데이터, μ: 평균, σ: 표준편차)
    - 판단: Z-점수의 절대값이 특정 임계값(일반적으로 2 또는 3)을 초과하면 이상치로 간주.
    - 특징: 데이터가 정규 분포를 따른다고 가정할 때 효과적.
  - IQR (Interquartile Range) 방법
    - 데이터의 사분위수를 이용하여 정상 범위를 설정하고, 이 범위를 벗어나는 값을 이상치로 판단
    - 데이터 분포의 극단값에 덜 민감(Robust).
    - 계산: IQR=Q3(제3사분위수)−Q1(제1사분위수)
    - 정상 범위: [Q1−1.5×IQR,Q3+1.5×IQR]
    - 판단: 데이터가 위 정상 범위를 벗어나면 이상치로 간주.
    - 특징: 데이터 분포에 대한 가정이 Z-점수보다 덜 엄격함.



이상탐지 알고리즘 개요 – 전통적 이상탐지

- 이미지 패턴 기반 이상 탐지 – 픽셀 및 템플릿
  - 템플릿 매칭 (Template Matching)
    - 개념: 정상 상태의 기준 이미지(템플릿)와 현재 검사 대상 이미지를 비교하여 차이를 분석.
    - 템플릿 이미지를 입력 이미지 위에서 이동시키면서 가장 유사한 위치를 찾음.
    - 유사도 측정 방법: NCC (Normalized Cross Correlation), SSD (Sum of Squared Differences) 등
    - 최대 유사도 값이 특정 임계값보다 낮거나, 예상 위치와 다르면 이상으로 판단.
    - 활용 예시 : 특정 부품의 누락, 잘못된 부품 조립, 로고나 마킹의 유무 및 위치 이상 검출.

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 이미지 패턴 기반 이상 탐지 – 픽셀 및 템플릿
  - 픽셀 값 비교 / 차이 이미징 (Pixel-wise Comparison / Difference Imaging)
    - 두 이미지(예: 기준 정상 이미지와 현재 입력 이미지) 간의 동일 위치 픽셀 값 차이를 분석.
    - 두 이미지의 차이(Difference) 이미지를 생성.
    - 차이 이미지에서 픽셀 값이 특정 임계값을 초과하는 영역을 이상 영역으로 검출.
    - 활용 예시
      - 배경이 고정된 상태에서 제품 표면의 스크래치, 얼룩, 이물질 등 미세한 변화 감지
    - 고려사항: 조명 변화, 미세한 위치 변화에 민감할 수 있음.

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 이미지 패턴 기반 이상 탐지 – 형태학적 특징과 구조 분석
  - 엣지 검출 (Edge Detection)
    - 이미지 내에서 객체의 경계나 윤곽선, 즉 밝기가 급격하게 변하는 부분을 찾아내는 기법.
    - 방법: Sobel, Canny, Laplacian 등의 엣지 검출 필터(연산자)를 사용.
    - 추출된 엣지의 연결성, 두께, 예상치 못한 엣지의 출현 등으로 이상 유무 판단.
    - 활용 예시
      - 제품의 외형 불량(깨짐, 갈라짐, 찌그러짐), 부품의 손상, 표면의 균열 검출.

이상탐지 알고리즘 개요 – 전통적 이상탐지

- 전통적 이상 탐지: 강점, 약점 그리고 쓰임새
  - 장점: 직관성 및 해석 용이성: 알고리즘의 결정 과정을 이해하기 쉬움.
    - 낮은 계산 복잡도: 일반적으로 빠른 처리 속도, 적은 시스템 리소스 요구.
    - 구현 용이성: 상대적으로 간단한 수학적/논리적 연산으로 구현 가능.
    - 특정 문제에 대한 높은 효율성: 문제 정의가 명확하고 변동성이 적은 경우 효과적.
  - 단점: 복잡하고 비정형적인 패턴 탐지 한계: 미묘하거나 새로운 유형의 이상 탐지에 어려움.
    - 수동 임계값 설정 및 튜닝: 최적의 임계값을 찾기 위해 많은 실험과 조정 필요.
    - 환경 변화에 취약: 조명, 위치, 제품 종류 변경 시 성능 저하 가능성 높음.
    - 다양한 예외 처리의 어려움: 규칙 기반의 경우, 모든 예외 상황을 사전에 정의하기 어려움.
  - 주요 활용 분야
    - 결함의 특징이 명확하고 단순한 경우 (예: 특정 크기 이상의 구멍, 특정 색상의 이물질).
    - 실시간 처리가 매우 중요하고, 약간의 오탐을 감수할 수 있는 경우. 딥러닝 모델의 전처리 또는 후처리 단계에서 보조적인 역할로 사용.

이상탐지 알고리즘 개요 – 딥러닝 기반 이상탐지

- 전통적 이상 탐지 방법의 한계
  - 복잡하고 비정형적인 패턴 탐지의 어려움
  - 최적의 임계값 설정을 위한 많은 실험과 조정 필요
  - 조명, 위치, 제품 종류 변경 등 환경 변화에 취약할 수 있음
  - 규칙 기반의 경우 모든 예외 상황을 사전에 정의하기 어려움
- 딥러닝기반 이상 탐지의 이점
  - 복잡한 패턴 학습: 데이터 내의 미묘하고 복잡한 비정형적 패턴을 스스로 학습 가능
  - 특징 자동 추출 (Automatic Feature Extraction): 모델이 데이터로부터 직접 유용한 특징을 추출
  - 높은 정확도 달성: 충분한 데이터와 적절한 모델 사용 시 전통적인 방법보다 우수한 성능 기대
  - 다양한 데이터 유형 적용: 이미지뿐만 아니라 센서 데이터, 시계열 데이터 등 다양한 데이터에 적용 가능

이상탐지 알고리즘 개요 – 딥러닝 기반 이상탐지

- 주요 딥러닝 접근법 개요
  - 비지도 학습 (Unsupervised Learning)
    - 정상 데이터만 학습하여 이상을 판단 (예: Autoencoders, GANs)
  - 지도 학습 (Supervised Learning)
    - 정상 및 알려진 이상 데이터를 모두 학습하여 분류 (예: CNN)
  - 준지도 학습 (Semi-supervised Learning)
    - 소량의 레이블 된 데이터와 다량의 레이블 되지 않은 데이터를 함께 사용

딥러닝 기반 이상탐지

- 주요 딥러닝 모델 및 아키텍처
  - Autoencoders (AE)
    - 입력 데이터를 저차원 공간으로 압축(인코더) 후 다시 원본 데이터로 복원(디코더)하도록 학습
    - 정상 데이터의 주요 특징을 학습하는 데 중점.
    - 정상 데이터는 잘 복원되지만, 학습하지 않은 이상 데이터는 복원 시 오류(Reconstruction Error) 발생
    - 장점
      - 주로 정상 데이터만으로 학습 가능 (비지도 학습), 구현이 비교적 용이함.
    - 단점
      - 복원 오류의 임계값 설정이 필요
      - 매우 새롭거나 복잡한 유형의 이상에는 둔감할 수 있음
      - 때로는 이상 데이터도 잘 복원하는 문제 발생.

딥러닝 기반 이상탐지

- 주요 딥러닝 모델 및 아키텍처
  - Generative Adversarial Networks (GANs)
    - 실제 데이터와 유사한 가짜 데이터를 생성하는 생성자(Generator)와 이를 실제 데이터와 구별하는 판별자(Discriminator)가 서로 경쟁하며 학습
    - 이상 탐지 방법
      - 정상 데이터의 분포를 학습한 GAN 이용, 입력된 데이터가 정상 분포에서 얼마나 벗어나는지를 측정
    - 장점
      - 매우 현실적인 정상 데이터 분포를 학습할 수 있어, 미묘한 이상 탐지에 잠재력.
    - 단점
      - 학습 과정이 불안정하고 많은 양의 데이터 및 튜닝 필요, 이상 점수(anomaly score) 정의가 다양함.

딥러닝 기반 이상탐지

- 주요 딥러닝 모델 및 아키텍처
  - Convolutional Neural Networks (CNNs)
    - 이미지의 공간적 계층 구조로부터 특징을 효과적으로 추출 (필터, 풀링 등 활용).
    - 사전에 정의된 정상 및 다양한 유형의 불량 데이터를 사용하여 각 클래스를 분류하도록 CNN을 학습.
    - 정상 데이터의 특징만을 학습하여, 정상 범주에서 벗어나는 데이터를 이상으로 판단.
    - 장점: 알려진 유형의 결함에 대해서는 매우 높은 분류 정확도를 보임.
    - 단점: 많은 양의 레이블링 된 학습 데이터가 필요. 새로운 유형의 불량 탐지가 어려움.
  - Vision Transformers (ViT)
    - 이미지를 여러 개의 작은 패치(patch)로 나누고, 이 패치 시퀀스를 Transformer의 입력으로 사용하여 이미지의 전역적인 관계를 학습.
    - 패치 간의 관계를 모델링하여 이상 탐지.
    - 장점: 이미지의 전역적인 컨텍스트를 효과적으로 포착, 최근 다양한 비전 분야에서 우수한 성능.
    - 단점: 일반적으로 대량의 학습 데이터와 많은 계산 자원을 필요

데이터셋 구축

데이터셋 구축

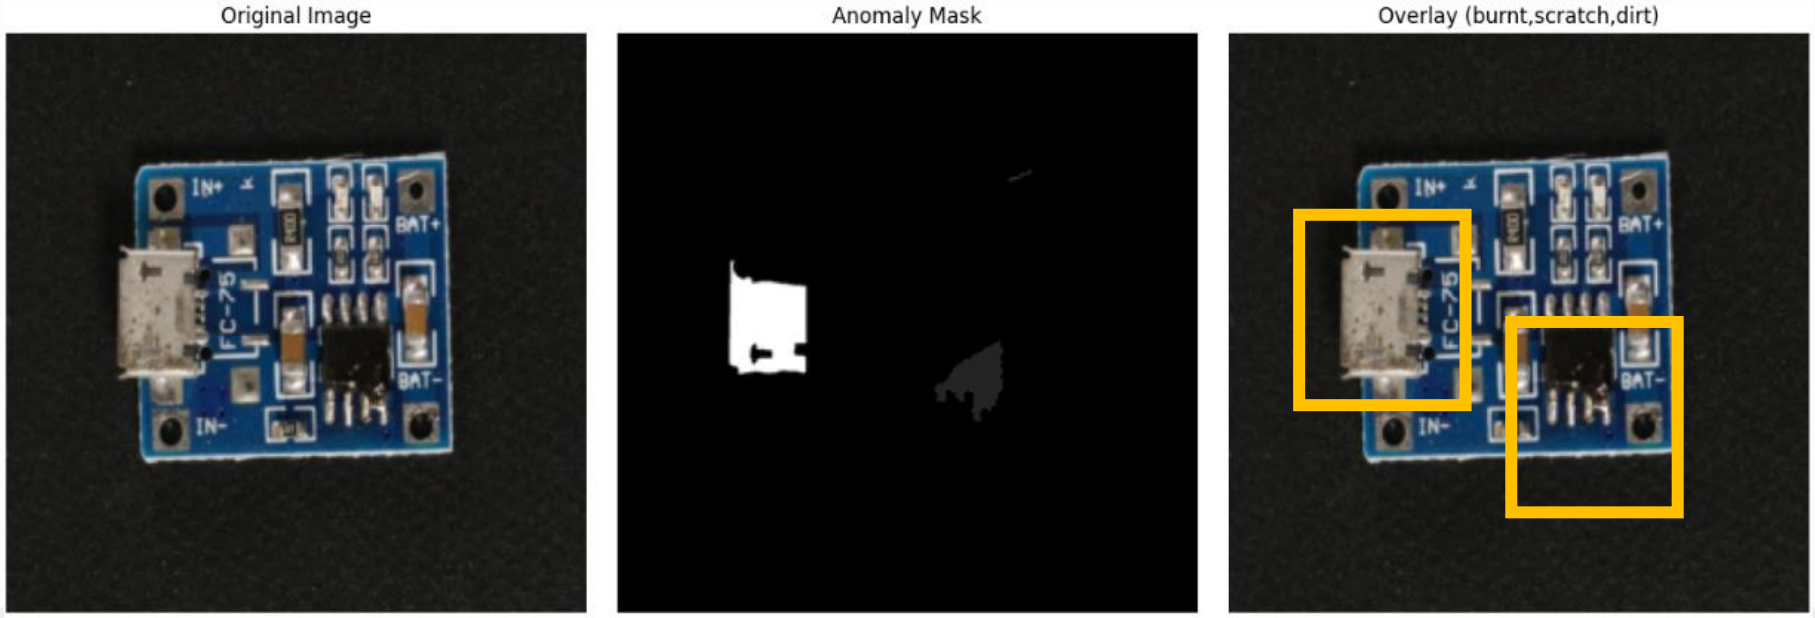
- 데이터 수집의 중요성
  - 모델의 성능은 데이터의 양과 질에 크게 좌우됨.
  - 제조 현장의 다양한 환경 변화(조명, 온도, 진동 등) 요소를 고려한 데이터 수집 필요.
- 정상 데이터 확보
  - 비지도 학습 기반 이상 탐지 모델의 경우, '정상' 상태를 정의하는 양질의 정상 데이터가 핵심.
  - 다양한 정상 상태를 포함해야 모델의 일반화 성능 향상.
- 비정상(이상) 데이터 확보
  - 실제 현장에서는 이상 데이터 발생 빈도가 낮아 수집이 어려움 (데이터 불균형 문제).
  - 이상의 종류가 매우 다양하고 예측 불가능한 경우가 많음.

데이터셋 구축

- 데이터 증강 (Data Augmentation)
  - 제한된 학습 데이터의 양을 늘리고 다양성을 확보하여 모델의 과적합(overfitting) 방지, 일반화 성능을 높임.
  - 이미지 회전, 반전, 크기 조절, 이동, 자르기, 밝기/대비 조절, 색상 변형, 노이즈 추가 등.
  - 실제 발생 가능한 결함과 유사한 형태를 인위적으로 생성하거나 합성하는 방법도 연구
    - Synthetic Anomaly Generation
- 데이터 전처리 (Data Preprocessing)
  - 이미지 크기 정규화: 입력 이미지 크기를 모델 요구사항에 맞게 통일.
  - 학습 안정성 및 속도 향상
    - 픽셀 값 정규화/표준화: 픽셀 값을 특정 범위(예: 0~1 또는 -1~1)로 조정 또는 평균 0, 표준편차 1로 변환
  - 노이즈 제거: 필요한 경우, 학습 전에 이미지 노이즈 제거 필터 적용.

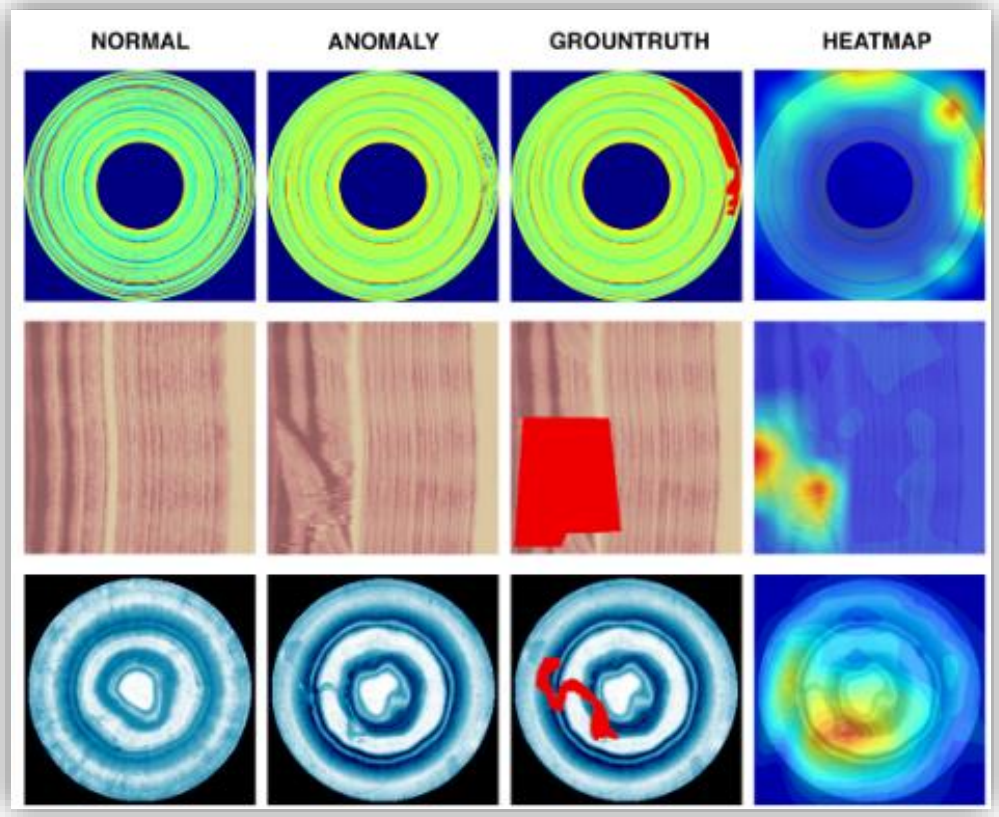
데이터셋 구축

- Visual Anomaly Dataset
  - **개요:** Anomaly detection 연구를 위해 설계된 데이터셋
  - **구성**
    - **12개 카테고리 :** PCB, Pipe, 음식, 캡슐, 양초 등
    - **결함 유형 :** 균열, 컷팅, 구멍, 흠집, 누락 등
    - **Pixel 레벨 annotation :** Segmentation mask 제공



데이터셋 구축

- 기타 데이터셋
  - MVTecAD: 산업용 이상 탐지를 위한 대표적인 벤치마크 데이터셋 (Non-commercial 라이선스)
  - BTAD: 실제 산업 환경에서 수집된 이상 탐지 데이터셋



VT-ADL : A Vision Transformer Network for Image Anomaly Detection and Localization

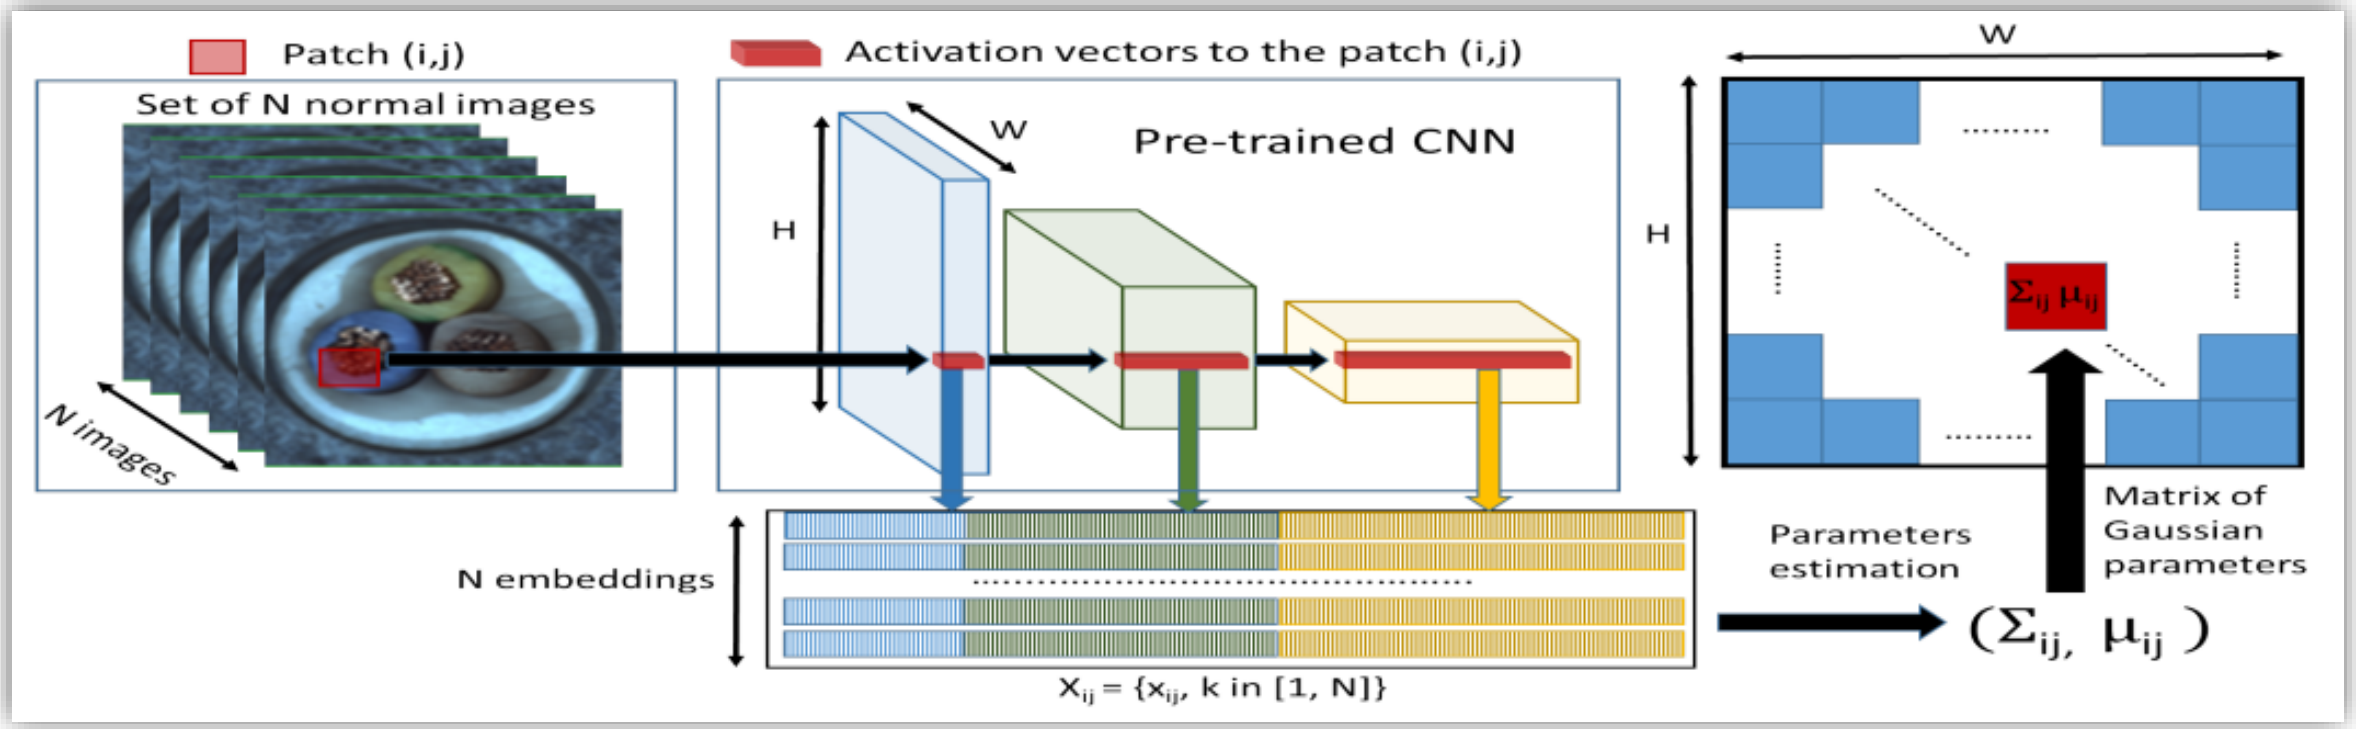
딥러닝 기반 이상 탐지 모델 구현

딥러닝 기반 이상 탐지 모델 구현

- PaDiM (Patch Distribution Modeling, https://arxiv.org/abs/2011.08785)
  - 핵심 원리:
    - 정상(결함 없는) 이미지 패치들의 통계적 표현을 학습
    - 이미지를 여러 패치로 나누고, 사전 학습된 CNN 을 사용하여 각 패치로부터 feature extraction
    - 정상 이미지들의 학습 데이터를 사용하여 각 패치 위치별로 추출된 feature들의 다변량 정규 분포 모델링
      - 즉, 각 패치 위치에 대한 평균 특징 벡터와 공분산 행렬을 저장
  - 이상 탐지 방식:
    - 새로운 검사 이미지가 입력되면, 동일한 방식으로 패치를 나누고 각 패치에서 특징 벡터를 추출합니다.
    - 추출된 각 패치의 특징 벡터와 해당 위치에 대해 학습된 정규 분포 사이의 거리 계산
      - 마할라노비스 거리 : Multivariate data 에서 변수간 상관관계를 고려해 거리 계산
    - 이 거리가 크면 해당 패치는 정상 분포에서 벗어난 것으로 간주되어 이상으로 판단

딥러닝 기반 이상 탐지 모델 구현

- PaDiM (Patch Distribution Modeling, https://arxiv.org/abs/2011.08785)
  - Pretrained CNN 을 이용해 feature extraction
  - Patch 단위로 이상치 탐지



딥러닝 기반 이상 탐지 모델 구현

- PaDiM (Patch Distribution Modeling, https://arxiv.org/abs/2011.08785)
  - 장점:
    - 비교적 적은 정상 데이터만으로도 좋은 성능
    - 학습 과정에서 정상 데이터만 사용합니다 (One-class learning).
    - 결함의 위치를 시각적으로 나타내는 “이상 점수 맵”을 제공하여 해석이 용이
  - 단점/고려사항:
    - 사전 학습된 CNN 모델의 선택이 성능에 영향을 줄 수 있음
    - 모든 패치 위치에 대한 정규 분포 파라미터(평균, 공분산 행렬의 역행렬 등) 저장
      - 이미지 크기나 패치 밀도에 따라 메모리 사용량이 클 수 있음

딥러닝 기반 이상 탐지 모델 구현

- CNN 기반 Autoencoder
  - 핵심 원리
    - 비지도 학습 신경망으로, CNN을 포함하는 인코더(Encoder)와 디코더(Decoder)로 구성
    - 인코더는 입력 이미지를 저차원의 잠재 공간(latent representation)으로 압축
    - 디코더는 이 잠재 공간 표현으로부터 원본 이미지를 다시 복원
    - 주로 정상(결함 없는) 데이터를 사용하여 학습, 모델은 정상 이미지의 특징을 학습하여 잘 복원하도록 훈련
  - 이상 탐지 방식:
    - 정상 이미지는 학습된 오토인코더에 의해 낮은 복원 오류(reconstruction error)로 잘 복원
    - 반면, 학습 데이터에서 보지 못한 이상(anomaly)이 포함된 이미지는 제대로 복원되지 않아 높은 복원 오류
    - 원본 이미지와 복원된 이미지 간의 차이(MSE 등)를 계산, 이 오류 값에 특정 임계값을 적용하여 이상 분류

딥러닝 기반 이상 탐지 모델 구현

- CNN 기반 Autoencoder
  - 장점
    - 정상 데이터만으로 학습이 가능하여 레이블링 비용이 적게 소요(비지도 학습)
    - 데이터 내의 복잡한 정상 패턴과 변형을 학습 가능
    - CNN을 통해 이미지의 공간적 계층 구조를 효과적으로 포착
  - 단점/고려사항
    - 적절한 복원 오류 임계값을 설정하는 것이 중요.
    - 오토인코더가 너무 일반화되어 일부 이상 패턴까지 잘 복원해버리는 경우가 발생할 수 있음
      - 이 경우, "새로운 불량 탐지"는 가능하지만 "해석성 부족"이 단점으로 언급되기도 함
    - 모델 구조와 데이터 크기에 따라 학습 시간이 오래 걸릴 수 있음

딥러닝 기반 이상 탐지 모델 구현

- SVM (Support Vector Machine) - One-Class SVM
  - 핵심 원리 (One-Class SVM)
    - SVM은 본래 지도 학습 기반의 분류 알고리즘이지만, One-Class SVM은 이상 탐지를 위해 변형된 형태
    - 주로 정상 데이터만을 사용하여 학습
    - 학습 데이터(정상 샘플)를 가장 잘 둘러싸는 경계(초평면, hyperplane)를 고차원 특징 공간에서 찾아냄
      - 이 경계는 정상 데이터의 분포를 나타냄
  - 이상 탐지 방식:
    - 데이터 포인트가 학습된 경계의 안쪽에 위치하는지 바깥쪽에 위치하는지를 판단
    - 경계 바깥쪽에 위치하는 데이터는 정상 데이터 분포에서 벗어난 것으로 간주되어 이상으로 분류
    - 커널 함수(예: RBF 커널, 다항식 커널)를 사용하여 비선형적인 데이터 분포도 효과적으로 모델링 가능

딥러닝 기반 이상 탐지 모델 구현

- SVM (Support Vector Machine) - One-Class SVM
  - 장점:
    - 수학적으로 잘 정립된 모델이며, 특정 조건에서 좋은 성능
    - 커널 트릭을 통해 고차원 공간에서의 복잡한 경계면 학습이 가능
  - 단점/고려사항:
    - 이미지 데이터에 직접 적용하기보다, 이미지로부터 추출된 특징 벡터를 입력으로 사용하는 경우가 많음
    - 따라서 특징 추출 방법의 성능이 전체 이상 탐지 성능에 큰 영향을 미칩니다.
    - 커널 함수의 종류와 해당 파라미터(예: RBF 커널의 gamma, nu 값) 선택에 매우 민감
    - 최적의 파라미터를 찾기 위한 튜닝이 필요
    - 학습 속도가 느림
    - 직접적으로 픽셀 단위의 이상 위치를 제공하기보다 이미지 전체 또는 특정 영역의 이상 여부를 판단