# 2차 회의 보고서

Oct 21, 2026 · @CV실습04

## 미팅 개요

| 항목 | 내용 |
|---|---|
| 일시 | 2026년 10월 21일(수) |
| 참석자 | 황예성, 이창민, 박서준 |

### 문제해결과정

1차 회의에서는 사전학습 YOLO로 사람을 충분히 잡을 수 있어 추가 학습은 필요 없다고 봤고, 테스트는 3D 시뮬레이션으로 먼저 하기로 했다. 룸 14개를 실제로 다 찍을 수 없어서, 스터디룸 14개 디지털 트윈에 가상 학생을 넣고 룸별 천장 카메라 화면을 YOLO 서버로 판정했다. 앉은 사람은 98.2%, 룸 판정은 92.0%(112장)로 나왔다.

하지만 세 가지 이유로 3D 시뮬레이션을 뺐다. 첫째, 가장 중요한 엎드린 사람 검출이 48.9%로, 같은 모델이 실제 사진에서는 6장을 모두 잡은 것과 정반대였다. 가상 인물의 모양과 질감이 실제 사람과 달라, 점수가 모델 성능이 아니라 그래픽의 한계를 재고 있었다. 둘째, 같은 장면도 렌더링 환경에 따라 결과가 달랐다. GPU 없이 렌더링하면 4명이 있는 룸을 0명으로 판정해, 테스트 결과를 믿고 결정을 내릴 수 없었다. 셋째, 우리가 알고 싶은 것은 실제 룸의 천장 각도·조명·테이블에서의 성능인데, 가상 화면을 실제에 맞추는 데 드는 시간이 실제 룸을 한 번 찍는 것보다 컸다. 그래서 하루 만에 시뮬레이션을 멈추고, 실제 룸 천장에 카메라를 달아 22분을 찍어 검증했다.

실제 영상을 돌려 보니 더 큰 문제가 나왔다. 사전학습 모델은 책상을 식탁(dining table)으로만 배워, 천장에서 내려다본 우리 테이블을 거의 찾지 못했다(YOLO26s 2%). 테이블을 못 찾으면 감지 영역을 만들 수 없다. 모델을 키우면 해결될지 보려고 사전학습 모델 16종을 같은 조건으로 비교했지만, 테이블과 엎드린 사람을 둘 다 잡는 모델은 없었다. 모델 크기가 아니라 데이터의 문제라고 보고 파인튜닝으로 방향을 바꿨다.

우리 룸에서 만든 데이터 727장(학습 637 + 검증 90)으로 학습했는데, 1차 학습은 테이블 위주 데이터라 테이블은 100%가 됐지만 사람을 잊어 버렸다(사람 100%→68%). 사람 데이터를 같이 넣고 학습률을 낮춘 v2에서 둘 다 해결했다.

엎드린 사람 사진이 부족해, 생성형 데이터로 채울 수 있는지 시험했다. 직접 찍은 빈 룸 사진의 의자 자리 4곳에 Stable Diffusion 인페인팅(사진 일부만 새로 그리는 기법)으로 엎드린 사람을 그려 넣고, CLIP으로 먼저 거른 뒤 눈으로 확인했다. 지시문과 옷차림을 바꿔 세 번(시험 16장, 2차 32장, 외투·후드·담요로 몸을 가린 어려운 장면 32장) 만들었고, 그중 엎드린 장면은 40장이다. 결과적으로 학습에는 쓰지 않았다. YOLO26s는 엎드린 장면 40장을 모두 잡아 새로 배울 것이 없었고, 진짜 약점이던 천장 각도의 테이블은 합성 사진으로 풀 수 없었으며, 1장 만드는 데 약 70초가 걸렸다. 대신 약점을 찾는 데는 쓸모가 있었다. 후드를 쓰고 엎드린 사람은 더 큰 YOLO26l도 신뢰도 0.14로 놓쳤고(26s는 0.42로 잡음), 의자에 외투만 걸린 사진은 어떤 모델도 사람으로 잡지 않았다. 그래서 시범 수집 때 후드 쓰고 엎드린 장면을 먼저 모으기로 했다.

테이블을 잡게 된 뒤에는 사각형 박스가 통로까지 덮어 지나가는 사람을 재석으로 세는 문제가 남아, SAM으로 테이블 테두리만 따서 감지 영역을 만들었다. 영역을 더 넓히면 유리벽 너머 옆방 사람까지 잡혀서, 영역은 +15%로 두고 겹침 기준을 25%에서 10%로 낮췄다. 최종 모델은 YOLO26s v2다.

마지막으로 판정을 어디서 할지 정했다. 1차 회의에서는 룸마다 라즈베리파이를 두고 그 안에서 직접 추론하는 안을 검토했고, 라즈베리파이 4B에서 같은 YOLO26s v2를 영상 659장으로 실측했다. 정확도는 같았지만 세 가지 이유로 쓸 수 없었다. 첫째, 1장에 2,832ms(초당 0.35장)가 걸려 1초마다 판정할 수 없었다. GPU 서버(18.1ms)보다 약 156배 느리다. 둘째, 최고 81.3°C까지 올라 하루 종일 돌리면 속도가 떨어지거나 고장 날 위험이 있다. 셋째, 14대를 따로 관리해야 하고 초기 비용도 약 240만 원으로 PC 한 대보다 크다. 그래서 라즈베리파이는 검토 후 제외하고, GPU가 있는 교내 PC 1대에서 14개 룸을 모두 판정하기로 했다. 클라우드 GPU는 빠르지만 월 약 60만 원이 들고 영상이 학교 밖으로 나가 함께 제외했다.

| 모델 | 파라미터 | 테이블 | 엎드린 사람 | GPU 1장 |
|---|---|---|---|---|
| YOLO26n (전) | 2.6M | 3% | 65.5% | 17.9ms |
| YOLO26s (전) | 10.0M | 2% | 92.9% | 21.0ms |
| YOLO11s v2 | 9.5M | 100% | 98.8% | 17.7ms |
| **YOLO26s v2 (최종)** | 10.0M | 100% | 100% | 18.1ms |
| YOLO26m v2 | 21.9M | 100% | 100% | 21.6ms |

학습에 안 쓴 영상 기준, GPU는 팀 노트북 RTX 5060·입력 960·30회 중앙값.

### 본 미팅의 주요활동

- 팀원별 실험 결과 공유(라즈베리파이 실측, 모델 비교·파인튜닝, 생성형 데이터 실험)
- 판정 위치·모델·감지 영역 최종 결정
- 교수님 피드백(타깃, 비용) 반영
- 발표 자료·보고서 점검

## 진행 사항

### 이번 미팅에서 한 일 (활동 내용)

1차 회의에서 정한 일을 모두 진행했다.

| 1차에서 정한 일 | 결과 |
|---|---|
| 모델과 임계값 합의 | 사전학습 16종 비교 후 YOLO26s v2로 결정, 엎드린 사람 기준값 0.35 |
| 실제 룸 고정 촬영 영상으로 판정 확인 | 천장 고정 카메라 영상 22분 촬영. 앞 80%는 학습, 뒤 20%는 시험에 사용 |

| 1차에서 정한 일 | 결과 |
|---|---|
| 라즈베리파이 속도 측정, 추론 위치 결정 | 라즈베리파이 4B 실측 1장 2,832ms(초당 0.35장), 최고 81.3°C → 교내 PC 1대 서버로 결정 |
| 책상 검출 보완 | 파인튜닝으로 테이블 검출 2% → 100% |
| 기획서 반영, PPT 초안 | 발표 슬라이드 16장, 프로젝트 보고서 작성 |

그 밖에 한 일:

- 3D 디지털 트윈에서 엎드린 사람 검출이 48.9%로 실제(6/6)와 달라 시뮬레이션 테스트를 중단하고 실제 영상 검증으로 바꿨다.
- Stable Diffusion으로 빈 룸 사진에 엎드린 사람을 그려 넣은 합성 사진 80장을 만들어 시험했다.
- 노트북 GPU 실측(1장 18.1ms)을 바탕으로 서버 최소 사양을 예측했다.
- 비용 계산표와 시스템 컨텍스트 다이어그램을 만들었다.
- MVP 사이트를 만들었다. 학습 데이터(실제 룸 천장 카메라 영상 22분)를 더미 데이터로 삼아 14개 룸을 가상으로 운영하는 관리자 대시보드 시뮬레이션으로, 룸 상태·부재 기록·통계·KPI·도입 전/후 비교를 보여 준다. 저녁 식사 시간 룸 활성화율은 도입 전 22%에서 도입 후 50%로 나왔다.

## 이번 미팅에서 한 일 (조치 사항)

- 판정은 교내 PC 1대에서 하기로 했다. 최소 GTX 1060급, 권장 GTX 1070급 + 라이젠 5 5600급 (약 50만 원).
- 룸별 라즈베리파이와 클라우드 GPU(월 약 60만 원, 영상 교외 전송)는 제외했다.
- 감지 영역을 테이블 박스 30% 확대에서 SAM 테이블 테두리 +15%로 바꾸고, 사람 박스 겹침 기준을 25%에서 10%로 낮췄다.
- 합성 데이터는 학습에 쓰지 않고, 약점(후드 쓰고 엎드린 사람)을 찾는 데 활용하기로 했다.
- 비용을 룸 단위 구독(룸당 월 1.5만 원)으로 정하고, 점검·고장 수리(출장비 제외)·재학습 인건비를 포함했다.
- 발표 자료와 GitHub에 올린 사람 이미지는 모두 모자이크했다.

## 논의 사항

| 주제 | 내용 | 결론 |
|---|---|---|
| 추론 위치 | 라즈베리파이 내부 추론 vs 서버 판정 | 라즈베리파이는 1초 간격 불가·과열로 제외, 교내 PC 1대 |
| 모델 크기 | nano는 엎드린 사람 65.5%, m·l은 정확도 같고 느림 | YOLO26s (GPU에서는 n과 속도 차이 거의 없음) |
| 학습 여부 | 1차에서는 사전학습으로 충분하다고 봤으나 테이블을 못 잡음 | 파인튜닝하기로 변경 |
| 감지 영역 | 사각형 박스는 통로까지 덮고, 더 넓히면 | SAM 테두리 +15%, 겹침 10% |

| 주제 | 내용 | 결론 |
|---|---|---|
| | 유리벽 너머 옆방이 잡힘 | |
| 타깃 | 교수님 피드백 "타깃을 정하라" | B2B: 고객은 학교, 사용자는 학생. 판단 기준 4가지(정확도·속도, 비용, 운영, 개인정보) |
| 비용 | 교수님 피드백 "비용이 최소인지, 오픈소스도 공짜가 아니다" | 초기 207만 원, 구독 연 252만 원 (학생지원비의 0.02%) |
| 합성 데이터 | 기존 모델이 이미 잡는 장면이라 학습에 새로 줄 정보가 없음 | 학습 제외, 약점 찾기에 활용 |

### 시도했다가 제외한 것

직접 해 보고 숫자로 판단해 버린 안이다. 걸린 기준은 학교 입장의 판단 기준 번호다(① 정확도·속도 ② 비용 ③ 운영·유지보수 ④ 개인정보).

| 시도 | 결과 | 걸린 기준 | 대신 고른 것 |
|---|---|---|---|
| 기존 CCTV 활용 | 한 화면에 여러 룸이 겹치고, 스터디룸 안에는 CCTV가 없음 | ① | 룸마다 카메라 1대 |
| 가정용 홈캠(앱 전용) | RTSP로 영상을 받을 수 없고 영상이 제조사 클라우드를 거침 | ④ | RTSP 지원 Tapo C210 |
| 3D 디지털 트윈 검증 | 엎드린 사람 48.9%(실제 사진은 6/6). GPU 없이 렌더링하면 4명을 0명으로 판정 | ① | 실제 사진·실제 룸 영상으로 검증 |
| 룸별 라즈베리파이 추론 | 1장 2,832ms(초당 0.35장), 최고 81.3°C, 14대 초기 약 240만 원 | ①②③ | 교내 PC 1대(GPU 1장 18.1ms) |
| 클라우드 GPU | 월 약 60만 원, 영상이 학교 밖으로 나감 | ②④ | 교내 PC 1대 |
| 사전학습 모델 그대로 사용 | 16종 중 테이블과 엎드린 사람을 둘 다 잡는 모델 없음(기존 YOLO11s 엎드림 6%) | ① | 우리 영상으로 파인튜닝 |
| 1차 파인튜닝 (테이블 위주) | 테이블은 100%지만 사람을 잊음(사람 100%→68%, 가방 89%→14%) | ① | 사람 데이터를 넣고 학습률을 낮춘 v2 |
| Stable Diffusion 합성 데이터로 학습 | 합성 80장(엎드린 장면 40장)을 기존 모델이 이미 잡아 새로 줄 정보가 없었고, 진짜 약점(천장 각도의 테이블)은 합성 사진에 없음 | ①② | 현장 데이터. 합성 사진은 약점 찾기에 활용 |
| 더 큰 모델 YOLO26m·l | 정확도는 같고 CPU에서 2.7~3.4배 느림 | ① | YOLO26s |

| 시도 | 결과 | 걸린 기준 | 대신 고른 것 |
|---|---|---|---|
| 더 작은 모델 YOLO26n | 엎드린 사람 65.5%, GPU에서는 s와 속도 차이 없음 | ① | YOLO26s |
| YOLO 테이블 박스를 30% 넓힌 감지 영역 | 사각형이라 비스듬한 테이블 옆 통로까지 덮어 지나가는 사람도 재석으로 셈 | ① | SAM 테이블 테두리 +15% |
| 감지 영역을 더 넓히기 | 유리벽 너머 옆방 사람까지 잡힘 | ① | 겹침 기준 25% → 10% |
| PoE 스위치·업체 시공·현황판 모니터 | 와이파이 홈캠이라 불필요, 현황판은 고도화 단계 | ② | 교내 와이파이 연결, 전기 공사만 (총 30만 원) |

## 팀 결정 사항 전체

| 분야 | 결정 | 이유 |
|---|---|---|
| 방향 | B2B: 고객은 학교 운영 담당, 사용자는 학생 | 교수님 피드백 "타깃을 정하라". 학생은 앱 설치·입력 없이 색만 봄 |
| 판단 기준 | ① 정확도·속도 ② 비용 ③ 운영·유지보수 ④ 개인정보 | 모든 선택을 학교 입장에서 비교하기 위해 |
| 카메라 | 룸마다 Tapo C210 1대(대당 45,900원), RTSP로 교내망 직접 수신, 교내 와이파이 연결, 천장에 고정해 책상이 잘 보이도록 설치 | 룸 하나 = 화면 하나, 업체 시공 불필요 |
| 신호등 | 가로형 3색 신호등을 문이나 문 위에 부착. 빨강 사용중, 노랑 30분 미만, 초록 30분 이상 | 복도에서 바로 보이게. 초록이면 짐을 룸 앞 바구니로 옮기고 사용 |
| 판정 서버 | 교내 PC 1대: 최소 GTX 1060급, 권장 GTX 1070급 + 6코어 라이젠 5 5600급 + 램 16GB(약 50만 원) | 룸 14개 × 1초 1장 = 1장 71ms 안. CPU는 카메라 14대 영상 디코딩 과부하 방지 |
| 모델 | YOLO26s v2(파인튜닝), 입력 960, 엎드린 사람 기준값 0.35 | 테이블·사람·엎드린 사람 모두 100%, NMS-free로 후처리 없음 |
| 데이터 | 727장(학습 637 + 검증 90). 천장 영상 앞 80%는 학습, 뒤 20%와 웹캠 영상은 시험에만 사용 | 학습에 안 쓴 영상으로 공정하게 평가 |
| 평가 지표 | 사람·엎드린 사람 검출률, 테이블 IoU 0.5 이상 비율, 1장당 처리 시간, 파라미터 수 | 사람을 놓치면 초록불이 켜져 짐을 치우게 됨. |

| 분야 | 결정 | 이유 |
|---|---|---|
| | | 속도·크기는 서버 비용과 직결 |
| 감지 영역 | SAM 테이블 테두리를 짧은 변의 15%만큼 부풀림, 사람 박스가 10% 이상 겹치면 재석. 설치 때와 테이블이 움직였을 때만 다시 딴 | 통로·옆방 오탐 방지 |
| 판정 보정 | 사람이 10초 넘게 안 보여야 부재, 2초 연속 보여야 재석 | 가려짐으로 인한 오판과 순간 오검출 방지 |
| 개인정보 | 얼굴 식별 없음, 영상 저장 없음, 교내망 밖 전송 없음, 색이 바뀐 순간 스냅샷만 모자이크해 1일 보관, 기록은 시각·룸·색만, 공개 자료도 모자이크 | 학생을 찍는 시스템이라 처음부터 설계에 포함 |
| 비용 | 초기 207만 원(카메라 64만, PC 50만, 신호등 49만, 전기 공사 30만, 부자재 14만). 구독 룸당 월 1.5만 원(점검·고장 수리·재학습 인건비 포함, 출장비 제외). 전기세는 학교 부담 | 오픈소스도 공짜가 아님. 룸 단위라 일부 룸부터 도입 가능. 연 252만 원 = 학생지원비의 0.02% |
| 시범 운영 | 학교 협조 → 7일 현장 수집(운영과 같은 천장 각도, 후드 쓰고 엎드린 장면 먼저) → 재학습·테스트 → 합격 시 적용 | 현장 데이터가 룸 1곳뿐이라 실증으로 채움 |
| 불합격·중단 기준 | 불합격: 관찰 300회 중 잘못된 초록 1건 이상 또는 빈 룸 놓침 2% 초과. 중단: 개인정보 검토 불통과 또는 분실·다툼 문의 주 3건 이상 | 잘못 켜진 초록 한 번이 곧 민원 |
| 고도화 | 1층 현황판, 짐 검출 | MVP 범위 밖, 초기 비용 최소화 |

## 추후 계획

### 다음 미팅에서 해야 할 일 (활동 내용)

다음 미팅은 최종 발표다. 미팅 전까지 아래 일을 끝낸다.

- PPT를 다듬는다: 팀원 수정본 반영, 수치 통일, 글자 넘침·잘림 확인
- 발표문을 다듬고 리허설해 발표 시간을 10~15분에 맞춘다.
- 예상 질문과 답변을 정리한다.
- 최종 발표를 한다.

### 다음 미팅에서 해야 할 일 (역할 분담)

| 담당 | 역할 | 맡는 일 |
|---|---|---|
| 황예성 | 총괄·통합 | PPT 제작, 발표, 프로젝트 전반 검수 |
| 이창민 | 라즈베리파이 | 라즈베리파이 실측·카메라 관련 질문 대비 |
| 박서준 | YOLO 검증·실험 | 모델 비교·실험 관련 질문 대비 |

### 다음 미팅에서 해야 할 일 (추진 일정)

| 날짜 | 내용 |
|---|---|
| 10/21(수) | PPT 다듬기, 발표문·Q&A 수정, 리허설 |
| 10/22(목) | 최종 발표 (10~15분 + 질의응답 약 10분) |
| 발표 이후 | 학교 협조 요청 → 7일 시범 수집 → 재학습·테스트 → 적용 |

## 기타

- 시범 운영 불합격 기준을 미리 정했다: 14개 룸을 하루 3번씩 7일, 약 300회 직접 관찰해 판정과 비교하고, 주인이 있는데 초록이 켜진 경우 1건 이상 또는 빈 룸을 놓친 경우 2%(6건) 초과면 재학습한다.
- 중단 기준: 개인정보 검토 불통과 또는 짐 분실·다툼 문의 주 3건 이상이면 장비를 철거하고 기록을 모두 삭제한다.
- 남은 문제: 현장 데이터가 룸 1곳(영상 22분)뿐이고, 룸 14개 동시 처리와 GTX 1060 실측은 아직 못 했다. 짐 검출이 없어 빈 책상도 30분을 기다리고, 30분 직전에 잠깐 들르면 타이머가 초기화된다.
- 고도화: 1층 현황판(층을 돌지 않고 빈 룸 확인), 짐 검출

## 황예성 개인 연구 보고: 테이블 파인튜닝, 감지 범위, 비용·서버 사양, MVP

담당: 총괄·통합. 2주차에는 사전학습 YOLO 16종 비교와 파인튜닝(학습 데이터 727장), SAM 감지 범위, 비용·서버 사양 계산, MVP 관제 대시보드, 발표 자료를 맡았다. 자료와 코드는 개인 저장소 MODU_CV의 2주차 폴더(https://github.com/hwang-ye-song/MODU_CV/tree/main/프로젝트_오픈스페이스_알박기감지/2주차)에 있다.

### 요약

실제 룸 천장 카메라 영상을 돌려 보니, 사전학습 YOLO는 천장에서 내려다본 우리 테이블을 거의 찾지 못했다(YOLO26s 2%). 사전학습 16종을 같은 조건으로 비교했지만 테이블과 엎드린 사람을 둘 다 잡는 모델이 없어, 우리 룸에서 학습 데이터 727장을 직접 만들어 파인튜닝했다. 1차 학습에서는 사람을 잊어버렸지만(100%→68%) 사람 데이터를 넣고 학습률을 낮춘 v2에서 테이블과 엎드린 사람을 모두 100% 잡았다. 사각형 테이블 박스가 통로까지 덮는 문제는 SAM 테두리 +15%와 겹침 기준 10%로 풀었다. 교수님 피드백에 맞춰 비용을 초기 207만 원, 연 252만 원(학생지원비의 0.02%)

으로 정리하고, 노트북 실측으로 서버 최소 사양을 GTX 1060급으로 정했다. 판정 방식과 도입 효과는 MVP 관제 대시보드로 보여 줬다(저녁 식사 시간 룸 활성화율 22%→50%).

## 1. 연구 질문

2주차에는 아래 다섯 가지 질문을 세우고, 각각 실험과 계산으로 답했다.

**표 1.** 연구 질문, 방법, 결론

| 번호 | 연구 질문 | 방법 | 결론 |
|---|---|---|---|
| RQ1 | 사전학습 YOLO로 천장 각도의 테이블과 엎드린 사람을 잡을 수 있는가 | 16종 × 실제 영상, 직접 센 정답으로 채점 | 불가. 727장으로 파인튜닝 → YOLO26s v2 |
| RQ2 | 사각형 테이블 박스로 만든 감지 범위의 한계를 어떻게 넘는가 | SAM 테두리 + 부풀리기, 겹침 기준 4가지 비교 | SAM 테두리 +15%, 겹침 10% |
| RQ3 | 학교가 낼 수 있는 최소 비용은 얼마인가 | 항목별 비용표, 학교 예산 비교 | 초기 207만 원, 연 252만 원 (학생지원비의 0.02%) |
| RQ4 | 서버는 어느 사양이면 충분한가 | 노트북 GPU 실측, 연산 성능 비율로 환산 | 최소 GTX 1060급, 권장 GTX 1070급 |
| RQ5 | 판정 방식과 도입 효과를 한눈에 보여 줄 수 있는가 | 실제 영상 22분을 더미 데이터로 쓴 관제 대시보드 | 저녁 식사 시간 활성화율 22%→50% |

## 2. 실험 환경과 데이터

**표 2.** 실험 환경

| 항목 | 내용 |
|---|---|
| 장치 | 팀 노트북(RTX 5060 Laptop GPU, 라이젠 7 250). 큰 모델(YOLO26m·l) 학습은 코랩 A100 |
| 소프트웨어 | Python, Ultralytics 8.4.176, PyTorch 2.11(CUDA 12.8), SAM 2.1 tiny, OpenCV |
| 입력 크기 | 960 (모든 실험 공통) |
| 시험 데이터 | A: 천장 고정 카메라 영상 1차.mp4(22분, 960×540) 중 학습에 쓰지 않은 뒤 20% · B: 라즈베리파이 웹캠 영상(18초, 3명 공부 중, 36장) · 엎드린 사람: 1차.mp4 마지막 7초(84프레임) |
| 학습 데이터 | 727장. 학습 637장(휴대폰 촬영 144 + 1차.mp4 앞 80% 475 + 엎드린 사람 사진 18), 검증 90장 (휴대폰 37 + 1차.mp4 53) |
| 기간 | 2026-10-18 ~ 10-21 |

## 3. 사전학습 모델 비교 (RQ1)

1주차에는 공용 테이블이 0.63~0.71로 잡혀 사전학습 모델로 충분하다고 봤다. 그런데 실제 룸 천장에 고정한 카메라 영상에서는 사전학습 YOLO가 우리 테이블을 거의 찾지 못했다(YOLO26s 2%). 책상을 식탁(dining table)으로만 배워, 높은 곳에서 내려다본 흰 테이블은 모르는 것이었다. 테이블을 못 찾으면 감지 범위를 만들 수 없다.

더 큰 모델이면 잡을지 보려고, 라즈베리파이 웹캠 영상에서 0.5초마다 뽑은 36장으로 크기별 11종(v8·11·12·26)과 구조가 다른 5종(v5u, v9, v10, RT-DETR, YOLO-World)을 같은 조건(입력 960, 기준 0.25)으로 돌렸다. 장면에 실제로 있는 개수(사람 3, 노트북 3, 휴대폰 2, 마우스 1, 가방 1, 테이블 1)를 직접 세어 정답으로 쓰고, 엎드린 사람은 1차.mp4 마지막 7초(84프레임)를 기준 0.35로 따로 채점했다.

**표 3.** 사전학습 16종 중 대표 8종 (웹캠 36장, 엎드린 사람 84프레임)

| 모델 | 물건 5종 | 테이블 | 엎드린 사람 | 파라미터 | CPU 1장 |
|---|---|---|---|---|---|
| yolov8n | 62% | 8% | 56.0% | 3.2M | 67ms |
| yolo11s | 72% | 0% | 6.0% | 9.5M | 142ms |
| yolo11l | 100% | 100% | 31.0% | 25.4M | 493ms |
| yolov9s | 85% | 92% | 2.4% | 7.3M | 181ms |
| yolov10s | 100% | 8% | 97.6% | 8.1M | 131ms |
| yolo26n | 63% | 3% | 65.5% | 2.6M | 69ms |
| yolo26s | 96% | 0% | 92.9% | 10.0M | 155ms |
| rtdetr-l | 100% | 72% | 91.7% | 33.0M | 1,055ms |

사람은 모든 모델이 잘 잡았지만, 테이블과 엎드린 사람을 둘 다 잡는 모델은 없었다. 테이블을 잡는 yolo11l은 엎드린 사람이 31%, 엎드린 사람을 잡는 yolov10s는 테이블이 8%였다. 모델 크기가 아니라 데이터의 문제라고 보고, 사전학습 모델 중에서 고르는 대신 우리 룸 영상으로 파인튜닝하기로 했다.

## 4. 학습 데이터와 파인튜닝 (RQ1)

테이블 라벨은 테이블을 잘 잡던 4개 모델(yolo11l, yolo11m, yolov9s, rtdetr-l)의 박스 중 가장 확실한 것을 후보로 쓰고, 휴대폰 영상 181장은 전부 눈으로 검수했다. 옆 룸의 작은 테이블을 잡은 3장은 본 테이블로 바꾸고, 테이블 절반만 잡은 1장은 손으로 다시 그렸으며, 의자까지 포함해 너무 커진 4장은 되돌렸다. 사람·물건 라벨은 엎드린 사람을 가장 잘 잡은 yolov10s로 자동 라벨링했다. 클래스 번호는 COCO 그대로(0=사람, 60=테이블) 둬서 기존 코드에 모델 파일만 바꿔 끼우면 되게 했고, 1차.mp4 뒤 20%와 웹캠 영상은 학습에 넣지 않고 시험에만 썼다.

**표 4.** 학습 데이터 구성

| 출처 | 장수 | 테이블 라벨 |
|---|---|---|
| 휴대폰으로 테이블 주변을 돌며 찍은 영상 18초 | 181장 (3프레임마다) | 4개 모델 후보 → 181장 전부 눈으로 검수, 틀린 박스는 손으로 수정 |
| 천장 고정 카메라 영상 1차.mp4 앞 80% | 528장 (2초마다) | 카메라가 고정이라 정답 박스 하나를 모든 프레임에 사용 |
| 위에서 찍은 엎드린 사람 사진 | 6장 × 3번 복사 | 4개 모델 후보 + 눈으로 검수 |

1차 학습은 테이블 위주(휴대폰 영상만)라, 테이블은 100%가 됐지만 사람과 가방을 잊어버렸다 (웹캠 사람 100%→68%, 가방 89%→14%, 엎드린 사람 6%→0%). 새 데이터에 맞추느라 원래 알던 것을 덮어쓴 것으로 보고, 1차.mp4 프레임과 엎드린 사람 사진을 함께 넣고 학습률을 낮춰(AdamW, lr0 0.001, 25에포크) v2를 학습했다. 백본을 고정한 학습과도 비교했지만 가방이 25%에 그쳐 전체 학습을 택했다.

**표 5.** 파인튜닝 전후 (학습에 쓰지 않은 영상 기준. A: 1차.mp4 뒤 20%, B: 웹캠)

| 모델 | 테이블 A | 테이블 B | 엎드린 사람 | 앉은 사람 | 파라미터 |
|---|---|---|---|---|---|
| YOLO11s 원본 | 95% | 0% | 6% | 100% | 9.5M |
| YOLO26s 원본 | 2% | 0% | 92.9% | 100% | 10.0M |
| YOLO11s v2 | 100% | 100% | 98.8% | 100% | 9.5M |
| YOLO26s v2 (최종) | 100% | 100% | 100% | 100% | 10.0M |
| YOLO26m v2 | 100% | 100% | 100% | 100% | 21.9M |

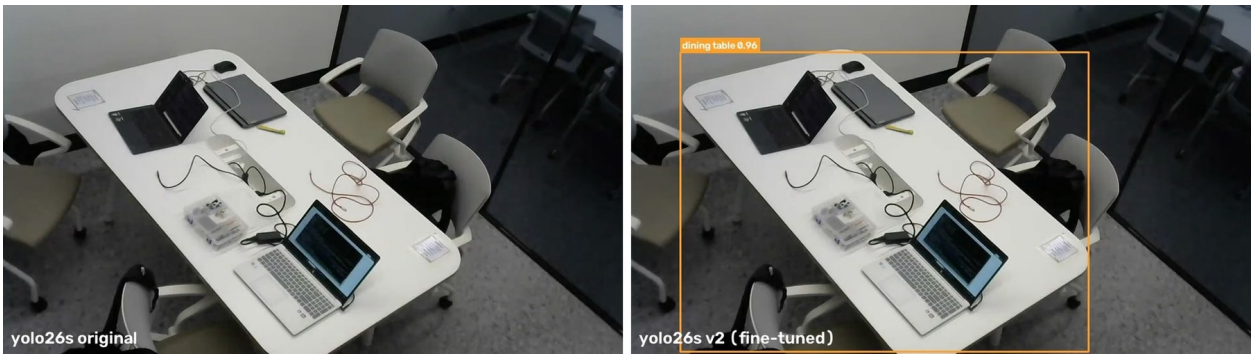



**그림 1.** 짐만 남은 빈 자리. 원본 YOLO26s(왼쪽)는 테이블을 잡지 못했고, 파인튜닝한 v2(오른쪽)는 신뢰도 0.96으로 잡았다

최종 모델은 파라미터 대비 성능으로 골랐다(그림 2). YOLO26n은 엎드린 사람이 65.5%(파인튜닝 전)라 사람이 있는데도 초록불이 켜질 위험이 있고, GPU에서는 s와 속도 차이도 거의 없었다(17.9ms 대 18.1ms). YOLO26m·l은 정확도가 s와 같으면서 CPU에서 2.7~3.4배 느렸다. 그래서 최종 모델을 YOLO26s v2로 정했다.

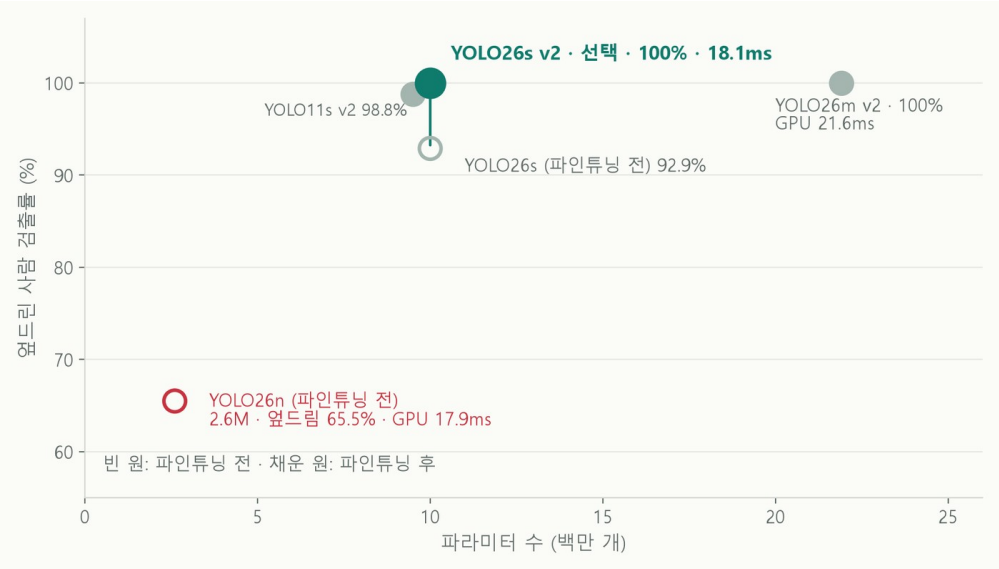



**그림 2.** 파라미터 수와 엎드린 사람 검출률. 빈 원은 파인튜닝 전, 채운 원은 파인튜닝 후다

## 5. 감지 범위: 테이블 박스에서 SAM 테두리로 (RQ2)

테이블을 잡게 된 뒤에도 문제가 남았다. 처음에는 YOLO 테이블 박스를 가로·세로 30% 넓혀 감지 범위로 썼는데, 박스는 사각형이라 비스듬히 놓인 테이블에서는 옆 통로까지 덮어 지나가는 사람도 재석으로 셌다. 박스를 넓히거나 줄이는 것만으로는 통로와 테이블 끝자리를 동시에 맞출 수 없어, 기존 YOLO 인식 범위의 한계라고 판단했다.

그래서 감지 범위를 세 단계로 만들었다(그림 3). ① 빈 룸에서 YOLO26s v2가 테이블 박스를 찾고, ② 그 박스를 SAM에 넣어 테이블 테두리만 딴 뒤, ③ 테두리를 짧은 변의 15%만큼 부풀린다. 사람에 가려지지 않은 빈 룸에서 한 번 따고, 테이블 위치가 달라진 상태가 30초 넘게 이어지고 사람이 없을 때만 다시 딴다.




**그림 3.** SAM 감지 범위 3단계. ① YOLO 테이블 박스 → ② SAM 테이블 테두리 → ③ 짧은 변의 15%만큼 부풀린 감지 범위

테이블 끝에 앉은 사람까지 잡으려고 범위를 더 넓히자 유리벽 너머 옆방 사람까지 잡혔다. 그래서 범위는 +15%로 두고, 사람 박스가 범위와 겹쳐야 하는 비율(겹침 기준)을 낮췄다. 1차.mp4에서 사람 555번을 기준별로 비교한 결과다.

**표 6.** 겹침 기준 비교 (1차.mp4, 사람 555번, 1초 단위 378초)

| 겹침 기준 | 사람별로 재석으로 센 비율 | 사람이 있는데 룸을 비었다고 본 순간 |
|---|---|---|
| 25% (처음) | 95.3% | 1초 |
| 15% | 96.9% | 1초 (마지막 사람이 나가는 순간) |
| 10% (최종) | 97.5% | 0초 |
| 1% | 99.5% | 0초 |

1%까지 낮추면 감지 범위에 살짝 닿기만 해도 재석이 되어, 짐만 남은 룸 앞 통로에 누가 서 있으면 부재 타이머가 계속 처음으로 돌아간다. 그래서 시험한 값 중 룸 판정이 틀린 순간이 없는 가장 높은 기준인 10%로 정했다. 이렇게 만든 감지 범위로 같은 룸의 신호등 색이 바뀌는 모습은 그림 4와 같다.

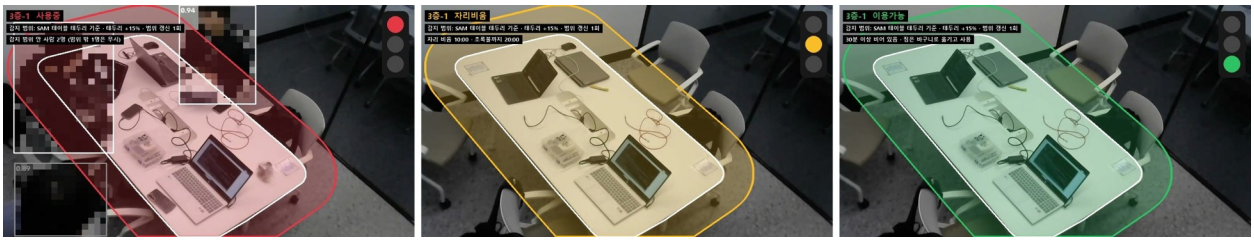


**그림 4.** 같은 룸의 판정. 왼쪽부터 빨강(사용 중), 노랑(자리 비움), 초록(이용 가능). 사람은 모자이크했다

## 6. 비용과 서버 사양 (RQ3, RQ4)

교수님 피드백("비용이 정말 최소인지 보여 줘라, 오픈소스도 공짜가 아니다")에 맞춰, 학교에 파는 B2B 기준으로 비용을 항목별로 계산했다(그림 5). 처음 계산에는 PoE 스위치, 업체 시공, 1층 현황판 모니터가 들어 있어 학교가 내기엔 컸다. 와이파이 카메라(Tapo C210)로 바꿔 PoE와 시공을 빼고, 현황판은 고도화 단계로 미뤘다. Tapo C210은 앱 전용 홈캠과 달리 RTSP로 영상을 직접 받을 수 있어, 영상이 제조사 클라우드를 거치지 않는다.




**그림 5.** 시스템 컨텍스트 다이어그램. 고객은 학교 운영 담당, 사용자는 학생이며, 판정은 교내 PC 1대에서 한다

**표 7.** 초기 비용 (룸 14개)

| 항목 | 계산 | 금액 |
|---|---|---|
| 카메라 (Tapo C210) | 14대 × 45,900원 | 64만 원 |
| 판정 서버 PC (DB 포함) | 1대 | 50만 원 |
| 문 앞 신호등 | 14개 × 35,000원 | 49만 원 |
| 전기 공사 | 전체 | 30만 원 |
| 카메라 고정 부자재 | 14곳 × 10,000원 | 14만 원 |
| PoE 스위치 · 1층 현황판 | 와이파이 카메라라 불필요 · 고도화 단계로 미룸 | 0원 |
| 합계 | 룸당 약 15만 원 | 207만 원 |

운영비는 룸 단위 구독으로 정했다. 룸당 월 1.5만 원(14개 룸이면 월 21만 원, 연 252만 원)이고, 점검·고장 수리(출장비 제외)·재학습 인건비를 넣었다. 룸 단위라 일부 룸부터 도입할 수 있다. 한양대 2026학년도 교비회계 자금예산서(ERICA)의 학생지원비 103.6억 원과 비교하면 연 구독료는 0.02%, 초기 비용을 더한 첫해도 0.04%다.

서버 최소 사양은 실측으로 정했다. 룸 14개를 1초에 1장씩 판정하려면 1장을 71ms 안에 처리해야 한다. 팀 노트북에서 YOLO26s v2(입력 960)를 30번 돌린 중앙값으로 재고, GPU 연산 성능(TFLOPS) 비율로 학교 PC급 GPU를 환산했다.

**표 8.** 1장 처리 시간과 서버 사양

| 방식 | 1장 처리 | 초당 처리 | 71ms 기준 |
|---|---|---|---|
| CPU만 (라이젠 7 250) | 135ms | 7.4장 | 부족 |
| CPU + GPU (RTX 5060 노트북, 실측) | 18.1ms | 55장 | 3.9배 여유 |
| GTX 1070 (6.5 TFLOPS, 환산) | 약 42ms | 약 24장 | 통과 |
| GTX 1060 (4.4 TFLOPS, 환산) | 약 62ms | 약 16장 | 통과, 여유 적음 |

그래서 최소 GTX 1060급, 권장 GTX 1070급으로 정했다. CPU는 카메라 14대의 영상을 받아 푸는 일을 맡으므로 6코어 라이젠 5 5600급, 램 16GB로 잡았다(PC 약 50만 원).

## 7. MVP 관제 대시보드 (RQ5)

판정 방식과 도입 효과를 말로 설명하면 이해하기 어려웠다. 눈으로 보는 것이 더 쉽다고 판단해, 우리 학습 데이터(실제 룸 천장 카메라 영상 22분)를 더미 데이터로 삼아 14개 룸을 가상으로 운영하는 관리자 대시보드를 만들었다. 룸 지도와 상태, 선택한 룸의 카메라 화면과 판정 근거, 부재 기록 조회, 통계·KPI, 1분 단위 데이터 기록(CSV), 1층 현황판 미리보기, 도입 전·후 비교를 한 화면에서 본다(그림 6).




**그림 6.** MVP 관제 대시보드, 도입 전 18:30. 14개 룸 중 사용 중 2개, 30분 넘게 짐만 있는 룸 8개, 룸 활성화율 14%

**표 9.** 도입 전 → 도입 후 (저녁 식사 시간, 같은 날 시나리오)

| 지표 | 도입 전 (아무도 안 치움) | 도입 후 (초록불 → 짐 치우고 사용) |
|---|---|---|
| 룸 활성화율 | 22% | 50% |
| 30분 넘게 짐만 있는 룸 평균 | 6.4개 | 0.6개 |
| 초록불이 켜진 뒤 다시 사용까지 평균 | 47분 | 2분 |

시뮬레이션이라 실제 운영 수치는 아니다. 실제 효과는 시범 운영에서 확인해야 한다.

## 8. 발표 자료 준비

실험 결과를 발표 자료로 묶었다(그림 7). 구성은 문제 → 타깃과 판단 기준 → 선택(카메라·판정 위치·모델·데이터) → 감지 범위와 판정 → 서버 사양 → 비용 → 개인정보 → MVP → 추후 계획

순서로, 무엇을 시도했고 왜 그렇게 정했는지가 이어지게 했다. 2차 회의에서 팀원들의 피드백을 받아 슬라이드를 고쳤다.

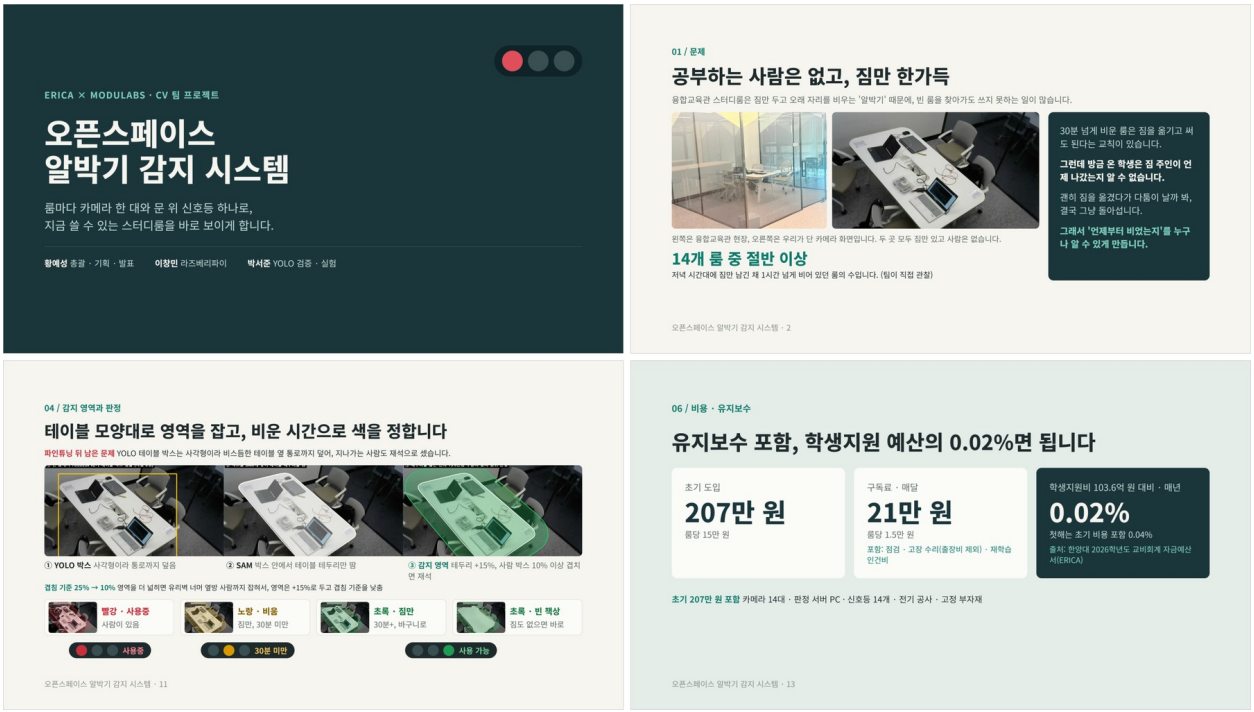



**그림 7.** 발표 자료 일부(최종본). 표지, 문제, 감지 범위와 판정, 비용

## 9. 결론

2주차의 기여는 다섯 가지로 정리된다.

- **데이터로 푼 테이블 문제:** 모델 크기가 아니라 데이터 문제임을 16종 비교로 확인하고, 727장 파인튜닝으로 테이블 2%→100%, 엎드린 사람 92.9%→100%를 얻었다. 1차 학습에서 사람을 잊은 문제도 데이터 구성과 학습률로 풀었다.
- **모양대로 잡는 감지 범위:** SAM 테두리 +15%와 겹침 기준 10%로 통로·옆방 오탐을 막으면서, 사람이 있는데 룸을 비었다고 보는 순간을 없앴다.
- **학교가 낼 수 있는 비용:** 초기 207만 원, 연 252만 원(학생지원비의 0.02%)으로 정리했다.
- **실측으로 정한 서버 사양:** 노트북 실측(1장 18.1ms)을 환산해 최소 GTX 1060급, 권장 GTX 1070급으로 정했다.
- **눈으로 보여 주는 결과:** MVP 관제 대시보드로 도입 효과(저녁 식사 시간 활성화율 22%→50%)를 한 화면에서 보여 줬다.